

# MVP - Engenharia de Dados

Operação em solo de aeroportos e companhias aéreas: identificação de gargalos operacionais

**Aluno(a):** *Emanuel Lacé Aranha*

**Email:** emmanuel.aranha00@gmail.com

**GitHub:** [https://github.com/Emanuel-Aranha/pos\\_puc\\_mvps](https://github.com/Emanuel-Aranha/pos_puc_mvps)

**Sprint:** Engenharia de Dados

**Plataforma:** Databricks Free Edition

## Contexto de Negócios e Perguntas (Etapa 2 e 4.1)

O setor de aviação civil brasileiro convive, de forma estrutural, com problemas de pontualidade, cancelamentos e gargalos operacionais em solo — atrasos que se propagam ao longo do dia, aeroportos com desempenho consistentemente pior que outros, e diferenças relevantes de eficiência entre companhias aéreas que operam nas mesmas condições de infraestrutura.

O objetivo deste trabalho é **identificar gargalos operacionais em solo nos principais aeroportos do Brasil**, cruzando indicadores de pontualidade, cancelamento e tempo de giro (turnaround) de aeronaves, de forma a apontar onde a causa provável do atraso está concentrada — no aeroporto, na companhia aérea ou em fatores sazonais.

### Perguntas de negócio

- 1) Quais são as piores taxas de pontualidade por aeroporto e por companhia aérea?
- 1.a) A pontualidade está melhorando ou piorando ao longo dos meses analisados?
- 2) Quais são as justificativas de atraso mais frequentes reportadas pelas companhias?
- 3) Qual o turnaround (tempo de giro em solo) médio por aeroporto?
- 3.a) Um turnaround médio alto se correlaciona com atraso médio de partida no mesmo aeroporto?
- 4) Quais aeroportos/companhias podem ser considerados referência de desempenho e quais são candidatos prioritários a intervenção operacional?
- 5) Existe sazonalidade na pontualidade (ex.: dezembro/janeiro e julho vs. demais meses)?
- 6) O gargalo observado é predominantemente do aeroporto ou da companhia aérea (dispersão de desempenho entre companhias no mesmo aeroporto)?

**Observação:** todas as perguntas foram mantidas conforme formuladas originalmente. A discussão sobre o que foi ou não plenamente respondido está na seção de Autoavaliação.

### Fonte de dados

Os dados utilizados são do VRA — Voo Regular Ativo, disponibilizado publicamente pela ANAC (Agência Nacional de Aviação Civil), contendo o registro de todos os voos regulares realizados no Brasil, com horários previstos e reais de partida e chegada, situação do voo e justificativas de atraso/cancelamento informadas pelas próprias companhias aéreas.

- Período analisado: 2023–2025
- Escopo geográfico: 15 maiores aeroportos do Brasil (origem ou destino)
- Granularidade: uma linha por etapa de voo (par origem-destino em uma data)

### Licença de uso

Os dados do VRA são publicados pela ANAC em seu Portal de Dados Abertos (<https://www.anac.gov.br/acesso-a-informacao/dados-abertos>), que segue a política federal de dados abertos do governo brasileiro.

## Carga dos Dados (Etapa 4.2)

A coleta foi dividida em duas etapas, em função de uma limitação de rede do compute serverless do Databricks Free Edition, que tem acesso restrito à internet externa e não permite download direto e confiável dos CSVs via requests dentro do notebook:

- **Fora do Databricks (máquina local):** execução do script `baixar_vra_anac.py`, que baixa todos os CSVs mensais do VRA diretamente do site da ANAC.
- **Dentro do Databricks:** upload manual da pasta VRA (contendo todos os CSVs) para um Volume do Unity Catalog ou para a Workspace pessoal.

Uma célula de localização automática (glob recursivo) procura a pasta VRA tanto dentro do Volume quanto na Workspace do usuário, e copia os CSVs encontrados para o Volume. Se a pasta não for encontrada em nenhuma das raízes candidatas, a célula interrompe a execução com um erro explícito (`FileNotFoundException` e mensagem orientando o próximo passo), em vez de falhar de forma pouco clara mais adiante no pipeline.

## Ingestão em camada Bronze

Os CSVs da ANAC usam separador ';' e encoding ISO-8859-1 (latin1). A ingestão faz:

- Sanitização dinâmica dos nomes de coluna (remoção de acentos, minúsculas, underscore) — resiliente a mudanças de layout entre anos.
- Renomeação para nomes curtos via dicionário de mapeamento (MAPA\_COLUNAS), incluindo a coluna `Codeshare`.
- Leitura de todos os campos como string (`inferSchema=False`) — a tipagem correta só ocorre na camada Silver, conforme o princípio da Arquitetura Medalhão de preservar o dado bruto sem alterações na Bronze.
- Checagem defensiva: se o Volume não tiver nenhum CSV, a célula interrompe com um erro explícito em vez de gerar uma tabela vazia silenciosamente.
- Adição de metadados de controle: `_arquivo_origem` (caminho do arquivo de origem) e `_data_ingestao` (timestamp da carga).
- Gravação como tabela Delta: `mvp_operacao_aerea.bronze.vra_voos`

Repositório com o script de coleta local e o notebook completo:

[https://github.com/Emanuel-Aranha/pos\\_puc\\_mvps/blob/main/baixar\\_vra\\_anac.py](https://github.com/Emanuel-Aranha/pos_puc_mvps/blob/main/baixar_vra_anac.py)

| A          |                                      | B             | C        | D      | E             | F              | G              | H                      | I                                                                       | J | K | L | M | N | O | P | Q | R | S | T | U |
|------------|--------------------------------------|---------------|----------|--------|---------------|----------------|----------------|------------------------|-------------------------------------------------------------------------|---|---|---|---|---|---|---|---|---|---|---|---|
| Sigla ICAO | Empresa                              | Empresa Aérea | Número V | Código | Código Tipo L | Modelo Equipam | Número de Asse | Sigla ICAO Aeroporto O | Descrição Aeroporto Origem                                              |   |   |   |   |   |   |   |   |   |   |   |   |
| ED         | SERVICIOS AEREOS PANAMERICANOS LTDA. | SARPA S A S   | 1234     | 0 I    | E45           |                | 50             | SAEZ                   | MINISTRO PISTARINI INTERNATIONAL AIRPORT (EZEIZA INTERNATIONAL AIRPORT) |   |   |   |   |   |   |   |   |   |   |   |   |
| ED         | SERVICIOS AEREOS PANAMERICANOS LTDA. | SARPA S A S   | 1234     | 0 I    | E45           |                | 50             | MMJN                   | CANCUEN INTL - CANCUEN INTL - MEXICO                                    |   |   |   |   |   |   |   |   |   |   |   |   |
| ED         | SERVICIOS AEREOS PANAMERICANOS LTDA. | SARPA S A S   | 5332     | 6 I    | E45           |                | 50             | SBEQ                   | EDUARDO GOMES - MANAUS - AM - BRASIL                                    |   |   |   |   |   |   |   |   |   |   |   |   |
| ED         | SERVICIOS AEREOS PANAMERICANOS LTDA. | SARPA S A S   | 5331     | 9 I    | E45           |                | 50             | SYCJ                   | CHEDDI JAGAN INTERNATIONAL AIRPORT - GEORGETOWN - GUYANA                |   |   |   |   |   |   |   |   |   |   |   |   |
| ED         | SERVICIOS AEREOS PANAMERICANOS LTDA. | SARPA S A S   | 25332    | 6 I    | E45           |                | 0              | SBEQ                   | EDUARDO GOMES - MANAUS - AM - BRASIL                                    |   |   |   |   |   |   |   |   |   |   |   |   |
| ED         | SERVICIOS AEREOS PANAMERICANOS LTDA. | SARPA S A S   | 5332     | 2 I    | E45           |                | 50             | SBEQ                   | EDUARDO GOMES - MANAUS - AM - BRASIL                                    |   |   |   |   |   |   |   |   |   |   |   |   |
| ED         | SERVICIOS AEREOS PANAMERICANOS LTDA. | SARPA S A S   | 5331     | 9 I    | E45           |                | 50             | SYCJ                   | CHEDDI JAGAN INTERNATIONAL AIRPORT - GEORGETOWN - GUYANA                |   |   |   |   |   |   |   |   |   |   |   |   |
| ED         | SERVICIOS AEREOS PANAMERICANOS LTDA. | SARPA S A S   | 25332    | 6 I    | E45           |                | 0              | SBEQ                   | EDUARDO GOMES - MANAUS - AM - BRASIL                                    |   |   |   |   |   |   |   |   |   |   |   |   |

| Partida Prev     | Partida Re | Sigla ICAO | Aeroporto D                                                           | Descrição Aeroporto Destino                  | Chegada Prev     | Chegada R | Situação  | Justificat | Referência | Situação Pa | Situação Che | Codeshare |
|------------------|------------|------------|-----------------------------------------------------------------------|----------------------------------------------|------------------|-----------|-----------|------------|------------|-------------|--------------|-----------|
| 01/10/2025 07:00 |            | MMJN       | CANCUEN INTL                                                          | CANCUEN INTL - MEXICO                        | 01/10/2025 12:00 |           | CANCELADO |            |            |             |              |           |
| 01/10/2025 16:00 |            | MDPC       | PUNTA CANA                                                            | PUNTA CANA - REPUBLICA DOMINICANA            | 01/10/2025 20:00 |           | CANCELADO |            |            |             |              |           |
| 01/10/2025 00:00 | *****      | SKBO       | EL DORADO INTERNATIONAL AIRPORT                                       | - BOGOTÁ - COLOMBIA                          | 01/10/2025 02:35 | *****     | REALIZADO |            |            | Pontual     | Pontual      |           |
| 15/10/2025 21:00 | *****      | SBEQ       | EDUARDO GOMES - MANAUS - AM - BRASIL                                  |                                              | 15/10/2025 22:40 | *****     | REALIZADO |            |            | Antecipado  | Antecipado   |           |
| 16/10/2025 00:00 | *****      | SKBO       | EL DORADO INTERNATIONAL AIRPORT                                       | - BOGOTÁ - COLOMBIA                          | 16/10/2025 02:35 | *****     | REALIZADO |            |            |             |              |           |
| 16/10/2025 00:00 | *****      | SKBO       | EL DORADO INTERNATIONAL AIRPORT                                       | - BOGOTÁ - COLOMBIA                          | 16/10/2025 02:35 | *****     | CANCELADO |            |            |             |              |           |
| 31/10/2025 21:00 | *****      | SBEQ       | EDUARDO GOMES - MANAUS - AM - BRASIL                                  |                                              | 31/10/2025 22:40 | *****     | REALIZADO |            |            | Antecipado  | Antecipado   |           |
| 01/10/2025 23:00 | *****      | SKBO       | EL DORADO INTERNATIONAL AIRPORT                                       | - BOGOTÁ - COLOMBIA                          | 01/10/2025 01:10 | *****     | REALIZADO |            |            |             |              |           |
| 01/10/2025 23:00 | *****      | KMA        | MIAMI INTERNATIONAL AIRPORT                                           | - MIAMI, FLORIDA - ESTADOS UNIDOS DA AMÉRICA | 02/10/2025 07:35 | *****     | REALIZADO |            |            | Antecipado  | Antecipado   |           |
| 01/10/2025 00:05 | *****      | SBGL       | AEROPORTO INTERNACIONAL DO RIO DE JANEIRO (GALEÃO) - ANTONIO CARLOS J |                                              | 01/10/2025 08:20 | *****     | REALIZADO |            |            | Pontual     | Pontual      |           |
| 01/10/2025 23:15 | *****      | KMA        | MIAMI INTERNATIONAL AIRPORT                                           | - MIAMI, FLORIDA - ESTADOS UNIDOS DA AMÉRICA | 02/10/2025 07:35 | *****     | REALIZADO |            |            | Antecipado  | Antecipado   |           |

## Modelagem e Catálogo de Dados (Etapa 4.3)

O modelo adotado é um esquema flat por conceito, típico de Data Lake, com uma tabela fato e três dimensões de apoio:

- **fVoos (fato):** uma linha por etapa de voo que toca os 15 aeroportos do escopo (como origem OU destino), com os dois lados da rota enriquecidos e a companhia identificada.
- **dAeroporto (dimensão):** todos os aeroportos observados na base (não só os 15 do escopo), com um indicador booleano de quais são monitorados.
- **dCia (dimensão):** companhias aéreas identificadas na base, com nome comercial derivado dos próprios dados.
- **dCalendario (dimensão):** datas de 2023-01-01 a 2025-12-31, com indicador de alta temporada.
- **turnaround\_estimado (tabela de apoio):** estimativa de tempo de giro em solo por aeroporto/companhia (proxy — ver limitações).

### Catálogo de dados

#### **dAeroporto (gold)**

Cobre todos os aeroportos observados como origem ou destino na base — não apenas os 15 do escopo.

| Coluna               | Tipo    | Descrição                                                                                                                                                                            |
|----------------------|---------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| icao                 | string  | Código ICAO do aeroporto. Chave primária.                                                                                                                                            |
| nome_aeroporto       | string  | Nome do aeroporto. Para os 15 aeroportos do escopo, nome curado manualmente; para os demais, derivado automaticamente da descrição bruta da ANAC (primeiro segmento antes de ' - '). |
| cidade_uf            | string  | Cidade/UF (aeroportos do escopo, curado) ou cidade/país (demais aeroportos, derivado da descrição bruta).                                                                            |
| aeroporto_monitorado | boolean | Indica se o aeroporto é um dos 15 do escopo deste MVP. Usado como filtro nas consultas de negócio da Etapa 6.                                                                        |
| descricao_aeroporto  | string  | Descrição bruta do aeroporto tal como veio no CSV da ANAC (mais frequente entre os arquivos mensais) — mantida para rastreabilidade/linhagem.                                        |

#### **dCia (gold)**

Cobre 100% dos códigos de companhia vistos na base, derivados dos próprios dados.

| Coluna   | Tipo   | Descrição                                                                                                                                                                                                                              |
|----------|--------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| icao     | string | Código ICAO da companhia aérea. Chave primária.                                                                                                                                                                                        |
| nome_cia | string | Nome comercial. Nome mais frequente (moda) da coluna 'Empresa Aérea' do CSV por código ICAO; um pequeno dicionário de exceções (mapa_cias_override) tem prioridade para os casos em que o nome bruto vem inconsistente entre arquivos. |

### ***dCalendario (gold)***

| Coluna         | Tipo    | Descrição                                                           |
|----------------|---------|---------------------------------------------------------------------|
| date           | date    | Data (2023-01-01 a 2025-12-31). Chave primária.                     |
| day_of_month   | int     | Dia do mês (1-31).                                                  |
| day_name       | string  | Nome do dia da semana.                                              |
| month          | int     | Mês (1-12).                                                         |
| month_name     | string  | Nome do mês.                                                        |
| quarter        | int     | Trimestre (1-4).                                                    |
| year           | int     | Ano.                                                                |
| days_in_month  | int     | Quantidade de dias no mês.                                          |
| alta_temporada | boolean | Indica se o mês é dezembro, janeiro ou julho — usado na Pergunta 5. |

### ***fVoos (gold)***

| Coluna                | Tipo      | Descrição                                                                                                                   |
|-----------------------|-----------|-----------------------------------------------------------------------------------------------------------------------------|
| icao_empresa          | string    | Código ICAO da companhia aérea que operou a etapa de voo. Chave estrangeira → dCia.icao.                                    |
| numero_voo            | string    | Número do voo.                                                                                                              |
| codigo_di             | string    | Código de identificação do documento de itinerário (DI).                                                                    |
| codigo_tipo_linha     | string    | Código do tipo de linha aérea (nacional, internacional, etc.).                                                              |
| modelo Equipamento    | string    | Modelo da aeronave utilizada na etapa.                                                                                      |
| numero_assentos       | int       | Número de assentos ofertados na aeronave (tipado como inteiro na Silver).                                                   |
| icao_origem           | string    | Código ICAO do aeroporto de origem. Chave estrangeira → dAeroporto.icao.                                                    |
| icao_destino          | string    | Código ICAO do aeroporto de destino. Chave estrangeira → dAeroporto.icao.                                                   |
| partida_prevista      | timestamp | Data/hora prevista de partida.                                                                                              |
| partida_real          | timestamp | Data/hora real de partida (nulo se o voo não decolou).                                                                      |
| chegada_prevista      | timestamp | Data/hora prevista de chegada.                                                                                              |
| chegada_real          | timestamp | Data/hora real de chegada (nulo se o voo não pousou).                                                                       |
| atraso_partida_min    | double    | Diferença em minutos entre partida real e prevista.                                                                         |
| atraso_chegada_min    | double    | Diferença em minutos entre chegada real e prevista.                                                                         |
| situacao_voo          | string    | Domínio esperado: REALIZADO, CANCELADO (confirmar valores distintos observados na Etapa 5).                                 |
| justificativa         | string    | Texto livre preenchido pela companhia aérea justificando atraso/cancelamento — não padronizado.                             |
| situacao_partida      | string    | Situação da partida informada pela companhia.                                                                               |
| situacao_chegada      | string    | Situação da chegada informada pela companhia.                                                                               |
| codeshare             | string    | Indicador de voo codeshare, conforme reportado pela ANAC. Disponível na Bronze; ainda não explorado nas 8 perguntas atuais. |
| nome_aeroporto_origem | string    | Nome do aeroporto de origem (join com dAeroporto por icao_origem).                                                          |

| Coluna                 | Tipo    | Descrição                                                                                                        |
|------------------------|---------|------------------------------------------------------------------------------------------------------------------|
| cidade_uf_origem       | string  | Cidade/UF do aeroporto de origem.                                                                                |
| origem_no_escopo       | boolean | true se icao_origem é um dos 15 aeroportos monitorados. Usado para filtrar consultas de pontualidade de partida. |
| nome_aeroporto_destino | string  | Nome do aeroporto de destino (join com dAeroporto por icao_destino).                                             |
| cidade_uf_destino      | string  | Cidade/UF do aeroporto de destino.                                                                               |
| destino_no_escopo      | boolean | true se icao_destino é um dos 15 aeroportos monitorados.                                                         |
| nome_cia               | string  | Nome comercial da companhia aérea (join com dCia por icao_empresa).                                              |

**Linagem:** fVoos e turnaround\_estimado derivam de silver.vra\_voos, que por sua vez deriva de bronze.vra\_voos (CSVs originais da ANAC, sem transformação). dAeroporto é derivada da própria Bronze (union de icao\_origem/icao\_destino com suas descrições), sobreposta pelos nomes curados dos 15 aeroportos do escopo. dCia é derivada da coluna 'Empresa Aérea' da própria Bronze, sobreposta por um pequeno dicionário de exceções.

## Chaves primárias e estrangeiras

Nenhuma chave primária ou estrangeira estava declarada na primeira versão do notebook — o relacionamento entre as tabelas existia só implicitamente, dentro dos joins do PySpark, e o Catalog Explorer do Databricks não desenhava nenhum relacionamento entre elas. A tabela abaixo resume as chaves adicionadas:

| Constraint                  | Tabela              | Coluna(s)                            | Tipo / Referência             |
|-----------------------------|---------------------|--------------------------------------|-------------------------------|
| pk_daeroporto               | dAeroporto          | icao                                 | PRIMARY KEY                   |
| pk_dcia                     | dCia                | icao                                 | PRIMARY KEY                   |
| pk_dcalendario              | dCalendario         | date                                 | PRIMARY KEY                   |
| pk_turnaround_estimado      | turnaround_estimado | aeroporto, icao_empresa, evento_hora | PRIMARY KEY                   |
| fk_fvoos_dcia               | fVoos               | icao_empresa                         | FOREIGN KEY → dCia.icao       |
| fk_fvoos_daeroporto_origem  | fVoos               | icao_origem                          | FOREIGN KEY → dAeroporto.icao |
| fk_fvoos_daeroporto_destino | fVoos               | icao_destino                         | FOREIGN KEY → dAeroporto.icao |
| fk_fvoos_dcalendario        | fVoos               | data_prevista_partida                | FOREIGN KEY → dCalendario     |
| fk_turnaround_daeroporto    | turnaround_estimado | aeroporto                            | FOREIGN KEY → dAeroporto.icao |
| fk_turnaround_dcia          | turnaround_estimado | icao_empresa                         | FOREIGN KEY → dCia.icao       |
| fk_turnaround_dcalendario   | turnaround_estimado | data_evento                          | FOREIGN KEY → dAeroporto.icao |

**Importante:** constraints de PRIMARY KEY/FOREIGN KEY no Delta/Unity Catalog são **informativas** — não são impostas pelo motor de escrita (o Delta não bloqueia, por exemplo, a gravação de uma linha

com uma chave estrangeira inválida). Elas documentam o modelo e habilitam o diagrama de relacionamento do Catalog Explorer. A garantia de integridade real vem de como o pipeline foi construído (as dimensões cobrem 100% dos códigos referenciados por fVoos, por construção) e é auditada explicitamente na Etapa 4.5 (Qualidade de Dados / Integridade Referencial), onde a contagem de órfãos deve ser zero.

## Pipeline de Dados (Etapa 4.4)

Todo o pipeline foi implementado em um único notebook Python, organizado em seções sequenciais (markdown + código) que seguem a Arquitetura Medalhão: Coleta (Bronze) → Modelagem + chaves primárias (Etapa 3) → Carga Silver/Gold + chaves estrangeiras (Etapa 4) → Qualidade e integridade referencial (Etapa 5) → Análise (Etapa 6). A opção por um notebook único, em vez de ramificar em vários notebooks por tabela, foi mantida por manter a leitura linear do fluxo completo mais simples de acompanhar e de reexecutar do zero — todas as escritas usam `overwriteSchema` para permitir reexecução mesmo quando o esquema de uma tabela muda.

### Bronze → Silver

- Conversão dos campos de data/hora (texto no formato dd/MM/yyyy HH:mm) para timestamp real.
- Conversão de `numero_assentos` para inteiro (antes permanecia como string).
- Cálculo de `atraso_partida_min` e `atraso_chegada_min` (diferença em minutos entre horário real e previsto).
- Filtro de escopo: mantém a etapa de voo se a origem OU o destino estiver entre os 15 aeroportos monitorados.
- Gravação como tabela Delta: `silver.vra_voos`
- Vale ressaltar, até mesmo como recomendação do professor durante uma das aulas de dúvidas, que os dados nulos não foram descartados a princípio, embora foi observado alguns dados de “data prevista de partida” nula durante o processo, não necessariamente era um erro pois podia ser um caso de voos remanejados ou então voos cancelados.



### Silver → Gold

- **dAeroporto e dCia:** construídas a partir da própria Bronze (ver Etapa 4.3), com chave primária declarada logo em seguida.
- **Estimativa de turnaround (proxy):** a base VRA não identifica a aeronave por matrícula, então o turnaround real por aeronave não pode ser calculado. Como proxy, o pipeline une os eventos de chegada e partida da mesma companhia no mesmo aeroporto, ordena por horário (Window function), e usa `lead()` para encontrar a próxima partida após cada chegada, descartando intervalos negativos ou maiores que 12h (720 min) como ruído.
- **fVoos:** join duplo de `silver.vra_voos` com `dAeroporto` (uma vez para origem, outra para destino) e com `dCia`, resultando na tabela gold consolidada com ambos os lados da rota nomeados. Em seguida, as chaves estrangeiras são declaradas (ver Etapa 4.3). Nessa etapa já fizemos o descarte dos dados de voos com data prevista de partida nula, por conta do intuito final do trabalho: Analisar atraso. Portanto, se não temos data prevista de partida, não conseguimos calcular o dado de atraso.

Scripts completos disponibilizados no repositório:

[https://github.com/Emanuel-Aranha/pos\\_puc\\_mvps/blob/main/MVP\\_ANAC\\_VRA.ipynb](https://github.com/Emanuel-Aranha/pos_puc_mvps/blob/main/MVP_ANAC_VRA.ipynb)

Além disso, é possível visualizar o schema flat nas imagens abaixo.



## Qualidade de Dados (Etapa 4.5)

A verificação de qualidade foi feita sobre a tabela gold.fVoos, cobrindo completude, consistência de domínio, outliers e integridade referencial:

- Completude: contagem e percentual de nulos para as colunas icao\_empresa, icao\_origem, icao\_destino, situacao\_voo, partida\_real e chegada\_real.
- Consistência de domínio: listagem dos valores distintos de situacao\_voo, para confirmar que o campo está restrito aos valores esperados.
- Outliers: contagem de registros com atraso de partida acima de 24h (1440 min), tratados como suspeitos de erro de digitação de data na fonte.

**Interpretação documentada no próprio notebook:** nulos em partida\_real/chegada\_real são esperados para voos com situacao\_voo = 'CANCELADO' e não devem ser removidos — apenas tratados como ausência de execução nas análises de pontualidade. Nulos em outros campos indicariam um problema de qualidade a investigar.


### Integridade referencial

Como as chaves estrangeiras do Unity Catalog são apenas informativas (não impedem uma escrita inconsistente), o notebook mede diretamente a integridade do modelo em vez de apenas presumi-la a partir das constraints declaradas:

- Contagem de voos sem nenhum aeroporto (origem ou destino) no escopo monitorado — esperado 0, valida o filtro da Silver.
- Contagem de voos com nome\_aeroporto\_origem ou nome\_aeroporto\_destino nulos — esperado 0, valida a cobertura completa da nova dAeroporto.
- Contagem de voos com nome\_cia nulo — esperado 0, valida a cobertura completa da nova dCia.

```
=== Checagem de integridade referencial (valida o modelo/PK/FK das Etapas 3-4) ===  
  
Voos sem NENHUM lado (origem/destino) no escopo monitorado (esperado: 0, é a checagem do filtro da Silver): 0  
Voos com nome_aeroporto_origem nulo (cobertura da nova dAeroporto, esperado: 0): 0  
Voos com nome_aeroporto_destino nulo (cobertura da nova dAeroporto, esperado: 0): 0  
Voos com nome_cia nulo (cobertura da nova dCia, esperado: 0): 0  
Voos com data_partida_prevista nula (partida_prevista não parseou, esperado: 0): 76131
```

Aqui podemos ver que existem diversos voos com data prevista de partida nula, apesar de ser um indicador de possível erro no processo, é possível interpretar de outra forma: Voos que foram cancelados. Para isso será necessário aprofundar por status do voo, como podemos ver abaixo



```
%sql  
select count(*) from fVoos  
where data_partida_prevista is null and situacao_voo = "REALIZADO"
```

| count(*) |
|----------|
| 76.13K   |

Com isso podemos entender que realmente existe uma inconsistência nos dados, afetando aproximadamente 3% da base. Não foi encontrado também nenhuma justificativa para esses dados estarem nulos. Dessa forma, foi reestruturada a base fVoos de modo que não constasse essas

inconsistências nos dados e que atrapalhasse as respostas das perguntas, repetindo o mesmo processo para “partida\_real” e “chegada\_real” (e situação voo não igual a realizado, pois voos não realizados deveriam ter partida\_real e chegada\_real nulas). Resultando em aproximadamente 2.7 M de linhas válidas.

## Análise de Dados (Etapa 4.5)

Cada pergunta de negócio definida no objetivo foi respondida por uma consulta SQL sobre a camada gold. Como fVoos agora traz os dois lados da rota (origem e destino), a maioria das consultas filtra explicitamente por origem\_no\_escopo — sem esse filtro, uma pergunta como 'pontualidade por aeroporto' poderia somar, para um mesmo aeroporto, tanto voos que realmente partiram dele quanto voos que só passaram por ele como destino, o que não faz sentido para um indicador de pontualidade de partida.

### Pergunta 1 — piores taxas de pontualidade por aeroporto e companhia

Calcula, para cada combinação aeroporto de origem × companhia, o percentual de voos pontuais (atraso de partida  $\leq 15$  min) entre os voos realizados que de fato partiram de um aeroporto do escopo (origem\_no\_escopo), considerando apenas combinações com mais de 100 voos.

```
O topo da tabela encontramos apenas linhas aéreas cargueiras, o que é interessante de analisar pensando que quando se trata de cargas, 15 minutos de atraso não é um tempo tão relevante assim. Porém mais no meio da tabela vemos que é bem distribuído, não parecendo um problema por companhia pois as mesmas companhias que estão mais no meio da tabela tem destaque também no bottom da tabela. Exemplo a azul, em guarulhos, tem 75% de pontualidade. Mas em outros aeroportos possuem mais que 80%, num contexto geral. Gerando a dúvida: Será que em grandes companhias como Gol, azul e Latam, o gargalo está mais relacionado ao aeroporto e não a companhia?
```

### Pergunta 1.a — evolução mensal da pontualidade

Agrupa o percentual de pontualidade por mês e por aeroporto de origem (origem\_no\_escopo), permitindo visualizar tendência de melhora ou piora ao longo do período 2023–2025.

```
Aqui não parece ter uma evolução clara, porém ao rodar a primeira query vemos claramente um outlier em maio de 2023. Ao rodar uma segunda query percebemos que estamos praticamente sem dados em maio de 2023, mostrando um erro na tabela. Investigando as origens vemos que o erro está em um dos CSV's de entrada.
```

### Pergunta 2 — justificativas de atraso mais frequentes

Normaliza o texto livre do campo justificativa (trim + upper) e conta a frequência de cada justificativa sobre todo o fVoos (sem filtro de origem\_no\_escopo, propositalmente — ver nota de escopo no notebook), calculando o percentual sobre o total de registros preenchidos.

Curiosamente as justificativas de atraso não estão preenchidas, verificando os csv's de entrada essa hipótese se confirma. As companhias não tem o costume de preencher essa informação ou o sistema que exportou os csvs para o site da ANAC não exporta essa informação.

### Pergunta 3 — turnaround médio por aeroporto

Junta `turnaround_estimado` com `dAeroporto` e calcula a média de `turnaround_min` por aeroporto, restringindo a `aeroporto_monitorado` (necessário agora que `dAeroporto` cobre todos os aeroportos, não só os 15 do escopo).

Observando os aeroportos com maiores turnaround vemos que Guarulhos, Eduardo Gomes e Galeão possuem valores muito altos, gerando um maior custo para a companhia aérea, visto que o avião no solo gera custo enquanto um avião no ar gera lucro. Assim percebemos também que Congonhas possui uma operação em solo exemplar, em questão de turnaround.

#### Pergunta 3.a — turnaround alto correlaciona com atraso médio de partida?

Cruza o turnaround médio por aeroporto com o atraso médio de partida por aeroporto (restrito a `origem_no_escopo`), agora também unido a `dAeroporto` para exibir o nome do aeroporto em vez de apenas o código ICAO.

Não existe uma correlação direta, mas os 2 aeroportos com maior turnaround tem também um alto atraso médio. Mas os valores intermediários oscilam, não confirmando essa hipótese. Além disso, Congonhas possui o menor turnaround e não possui o menor atraso médio

### Pergunta 4 — aeroportos/companhias referência vs. candidatos a intervenção

Combina, por aeroporto de origem (`origem_no_escopo`), o percentual de pontualidade e o percentual de cancelamento em uma única consulta, permitindo classificar aeroportos como referência (alta pontualidade, baixo cancelamento) ou candidatos a intervenção (padrão oposto).

Brasília lidera em pontualidade e percentual de cancelamento, sendo um ótimo candidato a aeroporto de referência em operação. Já como candidato a intervenção, temos Eduardo Gomes com um alto percentual de cancelamento e baixa pontualidade

### Pergunta 5 — sazonalidade

Junta `fVoos` com `dCalendario` por data e agrupa pontualidade e atraso médio por mês do ano, permitindo comparar dezembro/janeiro e julho (alta temporada) contra os demais meses. Diferente das perguntas anteriores, aqui não se filtra por `origem_no_escopo` — a sazonalidade é medida sobre todo o movimento que toca os aeroportos do escopo, partindo ou chegando.

Não parece existir uma piora por sazonalidade, mas existe sim uma piora no serviço no ultimo trimestre. Mas a hipótese é anulada quando julho, um mês de alta temporada, possui uma das maiores performances operacionais

### Pergunta 6 — gargalo é do aeroporto ou da companhia?

Calcula a pontualidade por aeroporto de origem × companhia (origem\_no\_escopo, com filtro de amostra mínima de 200 voos) para observar a dispersão de desempenho entre companhias dentro do mesmo aeroporto.

A resposta é bem simples analisando os dados acima> É a companhia e não o aeroporto.

A evidência mais forte é o aeroporto de viracopos, onde as cargueiras variam performance de 90% de pontualidade (FedEx) vs 14% de pontualidade (Atlas Air), mas não para por ai, em Guarulhos a azul possui 89% vs latam com 75%.

Outra evidência é a marcação de algumas empresas que performam consistentemente mal, como por exemplo a TAP, com todas as performances inferiores a 71%. Assim, entre outros casos, podemos concluir que a empresa que possui uma operação não ideal e não o aeroporto, podendo intensificar a piora caso o aeroporto não tenha um histórico bom, porém boas empresas continuam com boas performances mesmo nesses aeroportos que possuem atrasos constantes.

## Considerações finais

### Pontos de melhoria

- **Turnaround por proxy:** a base VRA não identifica a aeronave por matrícula, então o turnaround estimado (mesma companhia, mesmo aeroporto, próxima partida) é uma aproximação. Incorporar uma base com matrícula da aeronave (ex.: dados de tráfego aéreo do DECEA/Redemet) permitiria calcular o turnaround real por aeronave.
- **Nomes derivados para aeroportos fora do escopo:** para os aeroportos que não são um dos 15 do escopo, nome e cidade são derivados por um split simples da descrição bruta da ANAC ('NOME - CIDADE - PAÍS'). Para descrições em formato diferente do padrão, isso pode gerar nomes truncados ou pouco legíveis. Uma tabela de referência oficial de aeroportos (ex.: base IATA/OpenFlights) resolveria isso com mais precisão — não é crítico hoje porque esses campos só aparecem de forma secundária (nenhuma das 8 perguntas depende do nome de aeroportos fora do escopo).
- **Constraints informativas:** as chaves primária/estrangeira adicionadas ao Unity Catalog não são impostas pelo Delta — servem como documentação do modelo e para o diagrama de

relacionamento do Catalog Explorer. A garantia de integridade real depende de como o pipeline constrói as dimensões e é auditada na Etapa 5.

- **Justificativas de atraso não preenchidas:** A pergunta 2 não foi possível responder devido a falta das justificativas

## Autoavaliação

No fim das contas, fiquei bem satisfeito com o que consegui responder. As Perguntas 1, 1.a, 4, 5 e 6 saíram com respostas sólidas e o que mais me deixou confiante foi ver os resultados batendo entre si sem eu ter forçado. Guarulhos e Congonhas aparecem como o mesmo tipo de problema tanto na Pergunta 1 quanto na 4 e na 6, e Eduardo Gomes se repete como ponto fora da curva no cancelamento e depois de novo quando eu abro por companhia. Quando os números concordam assim, de lugares diferentes da análise, dá uma segurança boa de que não é coincidência.

A Pergunta 5 foi provavelmente a que mais me ensinou alguma coisa. Eu tinha entrado com a expectativa de que dezembro, janeiro e julho seriam os meses ruins, e não é bem isso que acontece. O que os dados mostram é uma piora que vai se acumulando de outubro pra novembro pra dezembro, e julho, pelo contrário, fica até acima da média do ano. Gostei de ter deixado a hipótese errada aparecer e mudado de ideia em cima do dado, em vez de tentar encaixar o resultado no que eu já esperava.

Já as Perguntas 2, 3 e 3.a eu diria que ficaram só parcialmente resolvidas, e aí o limite não foi de esforço, foi da própria base: o VRA não traz a matrícula da aeronave, então o turnaround que calculei é uma estimativa (mesma companhia, mesmo aeroporto, próxima partida saindo dali), não o tempo de giro real de um avião específico. Deixei isso documentado e chequei que a parcela de estimativas descartadas por serem ruído (mais de 12h de intervalo) era pequena, mas de toda forma é uma resposta aproximada, além disso a falta de justificativa é um fator crucial aqui para a resposta da pergunta 2.

Em termos técnicos, confesso que SQL e modelagem relacional não me pegaram de surpresa, já tinha visto isso em disciplinas anteriores. E a parte de engenharia de dados em si (ETL, as camadas Bronze/Silver/Gold, PySpark) também fluiu mais fácil do que eu esperava, provavelmente porque já tinha passado por algo parecido trabalhando como analista de dados na área de previdência privada, na XP, antes de entrar no curso. O que realmente me deu trabalho foi outra coisa: revisar o modelo relacional depois que percebi um erro que eu mesma tinha cometido sem perceber. Minha primeira versão da dAeroporto só cobria os 15 aeroportos do escopo, e isso fazia com que voos em que o aeroporto do escopo era o destino (e não a origem) simplesmente sumissem das análises agrupadas por aeroporto, sem erro nenhum aparecendo na tela, só um resultado sutilmente errado. Foi meio desconfortável perceber isso, porque eu já tinha rodado tudo e parecia que estava certo. Tive que reconstruir a dimensão do zero considerando todos os códigos ICAO da base pra só depois conseguir declarar chave primária e estrangeira de verdade. Teve também um bug de encoding, o arquivo é UTF-8 mas em sua documentação eu encontrei como encoding Latin-1, esse problema só ficou óbvio quando vi os nomes das companhias saindo com "Ã" no lugar de acento no resultado de uma query. Isso me ensinou uma lição que acho que vou levar: não basta o pipeline rodar sem erro, é preciso realmente olhar o dado que sai no fim. Fora do código, teve ainda uma dor de cabeça mais prática na coleta: o compute do Databricks Free Edition tem acesso restrito à internet, então não deu pra baixar os CSVs da ANAC direto pelo notebook, precisei baixar na minha máquina e subir manualmente.

Mas, sendo bem sincero, a parte mais difícil do trabalho inteiro não foi nada disso, pois a base técnica eu já tinha de empregos anteriores como analista de dados e também da graduação de engenharia de computação na USP. Foi entender a própria aviação. Eu gosto do assunto, sempre gostei, mas gostar de longe é bem diferente de conseguir explicar por que Viracopos concentra tanta carga, por que Manaus tem um perfil de cancelamento tão diferente do resto, ou o que exatamente significa turnaround na prática do dia a dia de um aeroporto. Passei bem mais tempo pesquisando sobre o setor para conseguir interpretar os números com um mínimo de propriedade do que efetivamente escrevendo código, no fim, foi a parte que eu mais gostei do processo inteiro, sair sabendo bem mais sobre aviação do que sabia quando comecei.

### Extra:

Devido a um problema encontrado na postagem do trabalho, não foi possível extrair o output do notebook. Apesar de ter procurado o problema em fóruns do próprio databricks (como: <https://community.databricks.com/t5/data-engineering/saving-ipynb-notebooks-to-git-does-not-include-output-cells/td-p/63434>) não foi possível encontrar uma solução. Então estou anexando os prints dos outputs por célula aqui, respeitando a numeração das células e o nome que está no próprio notebook.

Caso prefira corrigir com a versão sem a conexão no databricks, porém com os outputs diretamente no ipynb, basta acessar o arquivo MVP\_operacao\_aerea.ipynb disponível no link [https://github.com/Emanuel-Aranha/pos\\_puc\\_mvps/blob/main/MVP\\_Operacao\\_Aerea.ipynb](https://github.com/Emanuel-Aranha/pos_puc_mvps/blob/main/MVP_Operacao_Aerea.ipynb)

Célula 3: Etapa 2: Coleta de dados

```
Volume bronze: /Volumes/mvp_operacao_aerea/bronze/vra_raw
```

Célula 5: Localização de VRA

```
Pasta encontrada em: /Workspace/Users/emanuel.aranha00@gmail.com/VRA
CSVs encontrados na pasta: 35
Copiados para o volume agora: 0
Já estavam no volume: 35
Total de CSVs disponíveis no volume: 35
Primeiro: VRA_2023_01.csv
Último: VRA_2025_12.csv
```

Célula 7: Ingestão em bronze

> 2 dataframes: df\_bronze, df\_raw

Colunas finais: ['icao\_empresa', 'nome\_empresa\_raw', 'numero\_voo', 'codigo\_di', 'codigo\_tipo\_linha', 'modelo Equipamento', 'numero Assentos', 'icao\_origem', 'descricao\_aeroporto\_origem', 'partida\_prevista\_raw', 'partida\_real\_raw', 'icao\_destino', 'descricao\_aeroporto\_destino', 'chega da\_prevista\_raw', 'chegada\_real\_raw', 'situacao\_voo', 'justificativa', 'referencia', 'situacao\_partida', 'situacao\_chegada', 'codeshare', '\_a rquivo\_origem', '\_data\_ingestao']

Linhas na camada bronze: 2892126

|   | A <sub>C</sub> icao_empresa | A <sub>C</sub> nome_empresa_raw                   | A <sub>C</sub> numero_voo | A <sub>C</sub> codigo_di | A <sub>C</sub> codigo_tipo_linha | A <sub>C</sub> moc |
|---|-----------------------------|---------------------------------------------------|---------------------------|--------------------------|----------------------------------|--------------------|
| 1 | 1ED                         | SERVICIOS AADREOS PANAMERICANOS LTDA. SARPA S.A.S | Z3292                     | 6                        | I                                | E145               |
| 2 | 1ED                         | SERVICIOS AADREOS PANAMERICANOS LTDA. SARPA S.A.S | 3292                      | 9                        | I                                | E145               |
| 3 | 1ED                         | SERVICIOS AADREOS PANAMERICANOS LTDA. SARPA S.A.S | 3293                      | 6                        | I                                | E145               |
| 4 | 1ED                         | SERVICIOS AADREOS PANAMERICANOS LTDA. SARPA S.A.S | 3291                      | 2                        | I                                | E145               |
| 5 | 1ED                         | SERVICIOS AADREOS PANAMERICANOS LTDA. SARPA S.A.S | 3293                      | 3                        | I                                | E145               |

5 rows 16.174s runtime Refreshed 12h ago

Célula 10: Modelagem

> 8 dataframes: aeroportos\_destino, aeroportos\_origem, contagem\_descricao, dAer...

Total de aeroportos distintos na base: 584

Aeroportos monitorados (escopo do MVP): 15 de 15 esperados

|    | A <sub>C</sub> icao | A <sub>C</sub> nome_aeroporto | A <sub>C</sub> cidade_uf | A <sub>C</sub> aeroporto_monitorado | A <sub>C</sub> descricao_aeroporto                        |
|----|---------------------|-------------------------------|--------------------------|-------------------------------------|-----------------------------------------------------------|
| 1  | SBBE                | Val de Cans                   | Belém/PA                 | true                                | INTERNACIONAL DE BELÁDM/VAL DE CANS/JÁDILIO CEZAR RIBEIRO |
| 2  | SBBR                | Brasília                      | Brasília/DF              | true                                | PRESIDENTE JUSCELINO KUBITSCHK - BRASÁDILIA - DF - BRASIL |
| 3  | SBCF                | Confins                       | Belo Horizonte/MG        | true                                | TANCRCDO NEVES - CONFINS - MG - BRASIL                    |
| 4  | SBCT                | Afonso Pena                   | Curitiba/PR              | true                                | AFONSO PENA - SÃO JOSÁD DOS PINHAIS - PR - BRASIL         |
| 5  | SBEG                | Eduardo Gomes                 | Manaus/AM                | true                                | EDUARDO GOMES - MANAUS - AM - BRASIL                      |
| 6  | SBFL                | Hercílio Luz                  | Florianópolis/SC         | true                                | HERCÁDILIO LUZ - FLORIANÁDOPOLIS - SC - BRASIL            |
| 7  | SBFZ                | Pinto Martins                 | Fortaleza/CE             | true                                | PINTO MARTINS - FORTALEZA - CE - BRASIL                   |
| 8  | SBGL                | Galeão                        | Rio de Janeiro/RJ        | true                                | AEROPORTO INTERNACIONAL DO RIO DE JANEIRO (GALEÁDIO) - AN |
| 9  | SBGR                | Guarulhos                     | São Paulo/SP             | true                                | GUARULHOS - GOVERNADOR ANDRÁD FRANCO MONTORO - GUAR       |
| 10 | SBKP                | Viracopos                     | Campinas/SP              | true                                | VIRACOPOS - CAMPINAS - SP - BRASIL                        |
| 11 | SBPA                | Salgado Filho                 | Porto Alegre/RS          | true                                | SALGADO FILHO - PORTO ALEGRE - RS - BRASIL                |
| 12 | SBRF                | Guararapes                    | Recife/PE                | true                                | GUARARAPES - GILBERTO FREYRE - RECIFE - PE - BRASIL       |
| 13 | SBRJ                | Santos Dumont                 | Rio de Janeiro/RJ        | true                                | SANTOS DUMONT - RIO DE JANEIRO - RJ - BRASIL              |
| 14 | SBSP                | Congonhas                     | São Paulo/SP             | true                                | CONGONHAS - SÃO PAULO - SP - BRASIL                       |
| 15 |                     |                               |                          |                                     |                                                           |

15 rows 28.005s runtime Refreshed 12h ago

Célula 12: dCia

> 4 dataframes: contagem\_nome\_cia, dCia, mapa\_override\_df, nome\_cia\_moda

Companhias identificadas na base: 144

|    | icao | nome_cia                                                                             |
|----|------|--------------------------------------------------------------------------------------|
| 17 | ARE  | AIRES - AEROVÃDAS DE INTEGRACÃON REGIONAL S.A.                                       |
| 18 | ARG  | AEROLINEAS ARGENTINAS S/A                                                            |
| 19 | ARN  | AERONEXUS CORPORATE                                                                  |
| 20 | ARU  | ARUBA AIRLINES                                                                       |
| 21 | AVA  | AEROVIAS DEL CONTINENTE AMERICANO S.A. AVIANCA                                       |
| 22 | AWC  | TITAN AIRWAYS                                                                        |
| 23 | AXY  | AIR X CHARTER LTD                                                                    |
| 24 | AZG  | SILK WAY WEST AIRLINES                                                               |
| 25 | AZN  | COMPANHIA DE SERVICIOS DE TRANSPORTE AEREO AMASZONAS S/A.                            |
| 26 | AZP  | COMPANHIA DE AVIACION PARAGUAYA SOCIEDAD ANONIMA - PARANAIR (EX- AMASZONAS PARAGUAY) |
| 27 | AZQ  | SILK WAY AIRLINES                                                                    |
| 28 | AZU  | Azul                                                                                 |
| 29 | BAW  | BRITISH AIRWAYS PLC                                                                  |
| 30 | BOL  | TRANSPORTES AEREOS BOLIVIANOS                                                        |
| 31 | BOV  | BOA BOLIVIANA DE AVIACÃON                                                            |

144 rows 10.063s runtime Refreshed 12h ago

Célula 14: dCalendario

> dCalendario: pyspark.sql.connect.dataframe.DataFrame = [alta\_temporada: boolean, date: date ... 7 more fields]

Linhas em dCalendario: 1096

|   | alta_temporada | date       | day_name  | day_of_month | days_in_month | month | month_name |
|---|----------------|------------|-----------|--------------|---------------|-------|------------|
| 1 | true           | 2023-01-01 | Sunday    | 1            | 31            | 1     | January    |
| 2 | true           | 2023-01-02 | Monday    | 2            | 31            | 1     | January    |
| 3 | true           | 2023-01-03 | Tuesday   | 3            | 31            | 1     | January    |
| 4 | true           | 2023-01-04 | Wednesday | 4            | 31            | 1     | January    |
| 5 |                | 2023-01-05 | Thursday  | 5            | 31            | 1     | January    |

5 rows 7.291s runtime Refreshed 12h ago

Célula 16: Criação de PK

```
--- Colunas de chave como NOT NULL ---
OK: ALTER TABLE mvp_operacao_aerea.gold.dAeroporto ALTER COLUMN icao SET NOT NULL
OK: ALTER TABLE mvp_operacao_aerea.gold.dCia ALTER COLUMN icao SET NOT NULL
OK: ALTER TABLE mvp_operacao_aerea.gold.dCalendario ALTER COLUMN date SET NOT NULL
--- Chaves primárias das dimensões ---
OK: ALTER TABLE mvp_operacao_aerea.gold.dAeroporto DROP CONSTRAINT IF EXISTS pk_daeroporto
OK: ALTER TABLE mvp_operacao_aerea.gold.dAeroporto ADD CONSTRAINT pk_daeroporto PRIMARY KEY (icao)
OK: ALTER TABLE mvp_operacao_aerea.gold.dCia DROP CONSTRAINT IF EXISTS pk_dcia
OK: ALTER TABLE mvp_operacao_aerea.gold.dCia ADD CONSTRAINT pk_dcia PRIMARY KEY (icao)
OK: ALTER TABLE mvp_operacao_aerea.gold.dCalendario DROP CONSTRAINT IF EXISTS pk_dcalendario
OK: ALTER TABLE mvp_operacao_aerea.gold.dCalendario ADD CONSTRAINT pk_dcalendario PRIMARY KEY (date)
```

## Célula 18: silver voos

linhas na camada silver (filtradas ao escopo): 2784806

## Célula 20: tabela turnaround

Registros de turnaround estimado: 1408025

## Célula 22: chaves turnaround

```
--- turnaround_estimado: colunas de chave como NOT NULL ---
OK: ALTER TABLE mvp_operacao_aerea.gold.turnaround_estimado ALTER COLUMN aeroporto SET NOT NULL
OK: ALTER TABLE mvp_operacao_aerea.gold.turnaround_estimado ALTER COLUMN icao_empresa SET NOT NULL
OK: ALTER TABLE mvp_operacao_aerea.gold.turnaround_estimado ALTER COLUMN evento_hora SET NOT NULL
--- turnaround_estimado: chave primária composta ---
OK: ALTER TABLE mvp_operacao_aerea.gold.turnaround_estimado DROP CONSTRAINT IF EXISTS pk_turnaround_estimado
OK: ALTER TABLE mvp_operacao_aerea.gold.turnaround_estimado ADD CONSTRAINT pk_turnaround_estimado PRIMARY KEY (aeroporto, icao_empresa, evento_hora)
--- turnaround_estimado: chaves estrangeiras ---
OK: ALTER TABLE mvp_operacao_aerea.gold.turnaround_estimado DROP CONSTRAINT IF EXISTS fk_turnaround_daeroporto
OK: ALTER TABLE mvp_operacao_aerea.gold.turnaround_estimado ADD CONSTRAINT fk_turnaround_daeroporto FOREIGN KEY (aeroporto) REFERENCES mvp_operacao_aerea.gold.dAeroporto (icao)
OK: ALTER TABLE mvp_operacao_aerea.gold.turnaround_estimado DROP CONSTRAINT IF EXISTS fk_turnaround_dcia
OK: ALTER TABLE mvp_operacao_aerea.gold.turnaround_estimado ADD CONSTRAINT fk_turnaround_dcia FOREIGN KEY (icao_empresa) REFERENCES mvp_operacao_aerea.gold.dCia (icao)
OK: ALTER TABLE mvp_operacao_aerea.gold.turnaround_estimado DROP CONSTRAINT IF EXISTS fk_turnaround_dcalendario
OK: ALTER TABLE mvp_operacao_aerea.gold.turnaround_estimado ADD CONSTRAINT fk_turnaround_dcalendario FOREIGN KEY (data_evento) REFERENCES mvp_operacao_aerea.gold.dCalendario (date)
```

## Célula 24: fVoos

Registros sem partida\_prevista, movidos para fVoos\_rejeitados: 76131 de 2784806 (2.73%)  
Tabela fVoos (gold) pronta para consultas em SQL.

## Célula 26: chaves fVoos

```
--- fVoos: colunas de chave como NOT NULL ---
OK: ALTER TABLE mvp_operacao_aerea.gold.fVoos ALTER COLUMN icao_empresa SET NOT NULL
OK: ALTER TABLE mvp_operacao_aerea.gold.fVoos ALTER COLUMN numero_voo SET NOT NULL
OK: ALTER TABLE mvp_operacao_aerea.gold.fVoos ALTER COLUMN partida_prevista SET NOT NULL
--- fVoos: chave primária composta ---
OK: ALTER TABLE mvp_operacao_aerea.gold.fVoos DROP CONSTRAINT IF EXISTS pk_fvoos
OK: ALTER TABLE mvp_operacao_aerea.gold.fVoos ADD CONSTRAINT pk_fvoos PRIMARY KEY (icao_empresa, numero_voo, partida_prevista)
--- Chaves estrangeiras de fVoos para as dimensões ---
OK: ALTER TABLE mvp_operacao_aerea.gold.fVoos DROP CONSTRAINT IF EXISTS fk_fvoos_dcia
OK: ALTER TABLE mvp_operacao_aerea.gold.fVoos ADD CONSTRAINT fk_fvoos_dcia FOREIGN KEY (icao_empresa) REFERENCES mvp_operacao_aerea.gold.dCia (icao)
OK: ALTER TABLE mvp_operacao_aerea.gold.fVoos DROP CONSTRAINT IF EXISTS fk_fvoos_daeroporto_origem
OK: ALTER TABLE mvp_operacao_aerea.gold.fVoos ADD CONSTRAINT fk_fvoos_daeroporto_origem FOREIGN KEY (icao_origem) REFERENCES mvp_operacao_aerea.gold.dAeroporto (icao)
OK: ALTER TABLE mvp_operacao_aerea.gold.fVoos DROP CONSTRAINT IF EXISTS fk_fvoos_daeroporto_destino
OK: ALTER TABLE mvp_operacao_aerea.gold.fVoos ADD CONSTRAINT fk_fvoos_daeroporto_destino FOREIGN KEY (icao_destino) REFERENCES mvp_operacao_aerea.gold.dAeroporto (icao)
OK: ALTER TABLE mvp_operacao_aerea.gold.fVoos DROP CONSTRAINT IF EXISTS fk_fvoos_dcalendario
OK: ALTER TABLE mvp_operacao_aerea.gold.fVoos ADD CONSTRAINT fk_fvoos_dcalendario FOREIGN KEY (data_partida_prevista) REFERENCES mvp_operacao_aerea.gold.dCalendario (date)
```

Célula 28: check de qualidade

|   | A <sup>0</sup> coluna | 1 <sup>2</sup> total_linhas | 1 <sup>2</sup> qtd_nulos | 1.2 pct_nulos |
|---|-----------------------|-----------------------------|--------------------------|---------------|
| 1 | icao_empresa          | 2708675                     | 0                        | 0             |
| 2 | icao_origem           | 2708675                     | 0                        | 0             |
| 3 | icao_destino          | 2708675                     | 0                        | 0             |
| 4 | situacao_voo          | 2708675                     | 0                        | 0             |
| 5 | partida_real          | 2708675                     | 89291                    | 3.3           |
| 6 | chegada_real          | 2708675                     | 89291                    | 3.3           |

↓

6 rows

20.202s runtime

Refreshed 12h ago

valores distintos de situacao\_voo:

|               |
|---------------|
| situacao_voo  |
| CANCELADO     |
| REALIZADO     |
| NÃO INFORMADO |

Célula 31: check de qualidade 2

|                                                                                                               |
|---------------------------------------------------------------------------------------------------------------|
| === Checagem de integridade referencial (valida o modelo/PK/FK das Etapas 3-4) ===                            |
| Voos sem NENHUM lado (origem/destino) no escopo monitorado (esperado: 0, é a checagem do filtro da Silver): 0 |
| Voos com nome_aeroporto_origem nulo (cobertura da nova dAeroporto, esperado: 0): 0                            |
| Voos com nome_aeroporto_destino nulo (cobertura da nova dAeroporto, esperado: 0): 0                           |
| Voos com nome_cia nulo (cobertura da nova dCia, esperado: 0): 0                                               |
| Voos com data_partida_prevista nula (partida_prevista não parseou, esperado: 0): 0                            |
| fVoos: combinações duplicadas da PK (icao_empresa, numero_voo, partida_prevista) – esperado 0: 118            |
| turnaround_estimado: combinações duplicadas da PK (aeroporto, icao_empresa, evento_hora) – esperado 0: 0      |

Célula 35: Query pergunta 1

|    | A <sup>0</sup> nome_aeroporto_origem | A <sup>0</sup> nome_cia                          | 1 <sup>2</sup> total_voos | .00 pct_pontualidade |
|----|--------------------------------------|--------------------------------------------------|---------------------------|----------------------|
| 1  | Viracopos                            | ATLAS AIR INC                                    | 484                       | 14.0                 |
| 2  | Guarulhos                            | ATLAS AIR INC                                    | 686                       | 17.1                 |
| 3  | Eduardo Gomes                        | ATLAS AIR INC                                    | 394                       | 20.3                 |
| 4  | Guarulhos                            | LÃDINEA ÃDIREA CARGUEIRA DE COLOMBIA S.A - LANCO | 117                       | 20.5                 |
| 5  | Galeão                               | CARGOLUX AIRLINES INTERNATIONAL S/A              | 135                       | 21.5                 |
| 6  | Guarulhos                            | LAN CARGO S.A.                                   | 196                       | 28.6                 |
| 7  | Viracopos                            | LÃDINEA ÃDIREA CARGUEIRA DE COLOMBIA S.A - LANCO | 357                       | 29.7                 |
| 8  | Herclio Luz                          | LAN CARGO S.A.                                   | 120                       | 30.0                 |
| 9  | Viracopos                            | CARGOLUX AIRLINES INTERNATIONAL S/A              | 563                       | 31.1                 |
| 10 | Viracopos                            | LAN CARGO S.A.                                   | 918                       | 32.1                 |
| 11 | Afonso Pena                          | CARGOLUX AIRLINES INTERNATIONAL S/A              | 239                       | 33.1                 |
| 12 | Guararapes                           | ABSA - AEROLINHAS BRASILEIRAS S.A.               | 109                       | 33.9                 |
| 13 | Afonso Pena                          | LAN CARGO S.A.                                   | 205                       | 34.1                 |
| 14 | Eduardo Gomes                        | LÃDINEA ÃDIREA CARGUEIRA DE COLOMBIA S.A - LANCO | 178                       | 36.0                 |
| 15 | Afonso Pena                          | TAMPA CARGO S.A.                                 | 211                       | 40.3                 |

Célula 38: Query pergunta 1a

Table

+

|    | count(*) | mes                           |
|----|----------|-------------------------------|
| 1  | 80272    | 2023-01-01T00:00:00.000+00:00 |
| 2  | 68189    | 2023-02-01T00:00:00.000+00:00 |
| 3  | 76373    | 2023-03-01T00:00:00.000+00:00 |
| 4  | 71731    | 2023-04-01T00:00:00.000+00:00 |
| 5  | 10       | 2023-05-01T00:00:00.000+00:00 |
| 6  | 73548    | 2023-06-01T00:00:00.000+00:00 |
| 7  | 80583    | 2023-07-01T00:00:00.000+00:00 |
| 8  | 79005    | 2023-08-01T00:00:00.000+00:00 |
| 9  | 74903    | 2023-09-01T00:00:00.000+00:00 |
| 10 | 76186    | 2023-10-01T00:00:00.000+00:00 |
| 11 | 72449    | 2023-11-01T00:00:00.000+00:00 |
| 12 | 76360    | 2023-12-01T00:00:00.000+00:00 |
| 13 | 78889    | 2024-01-01T00:00:00.000+00:00 |
| 14 | 70773    | 2024-02-01T00:00:00.000+00:00 |
| 15 | 76023    | 2024-03-01T00:00:00.000+00:00 |

↓

37 rows

1.695s runtime

Refreshed 12h ago

Célula 39: Query pergunta 1a\_2

Table

+

|    | mes                           | pct_pontualidade |
|----|-------------------------------|------------------|
| 1  | 2023-01-01T00:00:00.000+00:00 | 80.9             |
| 2  | 2023-02-01T00:00:00.000+00:00 | 80.7             |
| 3  | 2023-03-01T00:00:00.000+00:00 | 84.6             |
| 4  | 2023-04-01T00:00:00.000+00:00 | 84.6             |
| 5  | 2023-05-01T00:00:00.000+00:00 | 62.5             |
| 6  | 2023-06-01T00:00:00.000+00:00 | 84.3             |
| 7  | 2023-07-01T00:00:00.000+00:00 | 84.5             |
| 8  | 2023-08-01T00:00:00.000+00:00 | 80.9             |
| 9  | 2023-09-01T00:00:00.000+00:00 | 82.2             |
| 10 | 2023-10-01T00:00:00.000+00:00 | 75.3             |
| 11 | 2023-11-01T00:00:00.000+00:00 | 77.1             |
| 12 | 2023-12-01T00:00:00.000+00:00 | 77.8             |
| 13 | 2024-01-01T00:00:00.000+00:00 | 77.7             |
| 14 | 2024-02-01T00:00:00.000+00:00 | 82.0             |
| 15 | 2024-03-01T00:00:00.000+00:00 | 83.3             |

↓

15 rows

1.060s runtime

Refreshed 12h ago

Célula 42: Query pergunta 2

Table

+

| justificativa_normalizada | ocorrencias | pct_do_total |
|---------------------------|-------------|--------------|
|---------------------------|-------------|--------------|

↓

0 rows

1.060s runtime

Refreshed 12h ago

Célula 45: Query pergunta 3

Table

+

🔍

🔗

📄

🗑️

|    | A <sub>C</sub> <sup>B</sup> nome_aeroporto | 1.2 turnaround_medio_min | 1.3 <sup>2</sup> qtd_amstras |
|----|--------------------------------------------|--------------------------|------------------------------|
| 1  | Guarulhos                                  | 75.6                     | 149879                       |
| 2  | Eduardo Gomes                              | 73.4                     | 27754                        |
| 3  | Galeão                                     | 71.4                     | 77992                        |
| 4  | Hercílio Luz                               | 62.8                     | 33470                        |
| 5  | Pinto Martins                              | 56.1                     | 30158                        |
| 6  | Salgado Filho                              | 49.7                     | 35400                        |
| 7  | Val de Cans                                | 48.5                     | 23393                        |
| 8  | Afonso Pena                                | 48.3                     | 41171                        |
| 9  | Dep. Luís Eduardo Magalhães                | 39.9                     | 40385                        |
| 10 | Santos Dumont                              | 38.5                     | 56296                        |
| 11 | Viracopos                                  | 38.4                     | 60538                        |
| 12 | Confins                                    | 32.3                     | 62283                        |
| 13 | Brasília                                   | 30.7                     | 59356                        |
| 14 | Guararapes                                 | 29.9                     | 43540                        |
| 15 | Congonhas                                  | 18.6                     | 127912                       |

↓

15 rows

1.583s runtime

Refreshed 12h ago

Célula 48: Query pergunta 3a

|    | A <sup>B</sup><br>C nome_aeroporto | 1.2 turnaround_medio | 1.2 atraso_medio   |
|----|------------------------------------|----------------------|--------------------|
| 1  | Guarulhos                          | 75.56819167461752    | 11.57124911654397  |
| 2  | Eduardo Gomes                      | 73.44249477552785    | 15.15400955921402  |
| 3  | Galeão                             | 71.41945327725921    | 7.482644090905488  |
| 4  | Hercílio Luz                       | 62.79002091425157    | 5.701998244220559  |
| 5  | Pinto Martins                      | 56.06522315803435    | 5.110209661098191  |
| 6  | Salgado Filho                      | 49.68225988700565    | 5.446639967018081  |
| 7  | Val de Cans                        | 48.50647629632796    | 4.744697914810194  |
| 8  | Afonso Pena                        | 48.335916057419055   | 3.9463557320738514 |
| 9  | Dep. Luís Eduardo Magalhães        | 39.92895877182122    | 4.226315195162039  |
| 10 | Santos Dumont                      | 38.47058405570556    | 3.31486238179072   |
| 11 | Viracopos                          | 38.44177211007962    | 9.719260897179554  |
| 12 | Confins                            | 32.30165534736606    | 5.962262931313105  |
| 13 | Brasília                           | 30.7486690477795     | 3.116083810766885  |
| 14 | Guararapes                         | 29.94414331649058    | 4.820369937624705  |
| 15 | Congonhas                          | 18.6332322215273     | 7.601342057325551  |

↓

15 rows

1.666s runtime

Refreshed 12h ago

Célula 51: Query pergunta 4

|    | A <sup>B</sup><br>C nome_aeroporto_origem | .00 pct_pontualidade | .00 pct_cancelamento |
|----|-------------------------------------------|----------------------|----------------------|
| 1  | Brasília                                  | 86.7                 | 1.6                  |
| 2  | Dep. Luís Eduardo Magalhães               | 84.2                 | 2.1                  |
| 3  | Guararapes                                | 83.6                 | 2.3                  |
| 4  | Pinto Martins                             | 83.6                 | 2.3                  |
| 5  | Val de Cans                               | 82.8                 | 2.5                  |
| 6  | Santos Dumont                             | 82.7                 | 3.5                  |
| 7  | Afonso Pena                               | 81.9                 | 3.8                  |
| 8  | Confins                                   | 81.1                 | 2.6                  |
| 9  | Hercílio Luz                              | 80.8                 | 3.8                  |
| 10 | Salgado Filho                             | 80.7                 | 3.8                  |
| 11 | Galeão                                    | 80.2                 | 2.7                  |
| 12 | Viracopos                                 | 79.0                 | 4.6                  |
| 13 | Congonhas                                 | 78.2                 | 2.5                  |
| 14 | Guarulhos                                 | 74.3                 | 2.9                  |
| 15 | Eduardo Gomes                             | 74.2                 | 7.7                  |

↓

15 rows

1.322s runtime

Refreshed 12h ago

Célula 54: Query pergunta 5

|    | 1.2.3 mes_do_ano | 1.2.3 mes | 1.2.3 alta_temporada | 1.00 pct_pontualidade | 1.2 atraso_medio_min | 1.2.3 total_voos |
|----|------------------|-----------|----------------------|-----------------------|----------------------|------------------|
| 1  | 1                | January   | true                 | 81.0                  | 7.6                  | 234.88K          |
| 2  | 2                | February  | false                | 81.6                  | 6.6                  | 205.88K          |
| 3  | 3                | March     | false                | 84.6                  | 5.4                  | 223.17K          |
| 4  | 4                | April     | false                | 84.7                  | 5.6                  | 217.37K          |
| 5  | 5                | May       | false                | 86.2                  | 5                    | 148.24K          |
| 6  | 6                | June      | false                | 84.6                  | 6.3                  | 217.32K          |
| 7  | 7                | July      | true                 | 84.2                  | 6.6                  | 239.28K          |
| 8  | 8                | August    | false                | 83.6                  | 7.3                  | 232.99K          |
| 9  | 9                | September | false                | 84.0                  | 6.6                  | 223.13K          |
| 10 | 10               | October   | false                | 80.1                  | 8.8                  | 227.33K          |
| 11 | 11               | November  | false                | 78.4                  | 9.2                  | 217.31K          |
| 12 | 12               | December  | true                 | 74.8                  | 12.2                 | 232.47K          |

↓

▼

12 rows1.626s runtime

Refreshed 12h ago

Célula 57: Query pergunta 6

|    | 1.2.3 nome_aeroporto_origem | 1.2.3 nome_cia                               | 1.00 pct_pontualidade | 1.2.3 total_voos |
|----|-----------------------------|----------------------------------------------|-----------------------|------------------|
| 1  | Afonso Pena                 | GOL                                          | 87.8                  | 16216            |
| 2  | Afonso Pena                 | Total Linhas Aéreas                          | 86.3                  | 1010             |
| 3  | Afonso Pena                 | Azul                                         | 85.9                  | 33805            |
| 4  | Afonso Pena                 | AEROLINEAS ARGENTINAS S/A                    | 85.3                  | 631              |
| 5  | Afonso Pena                 | AZUL CONECTA LTDA. (EX TWO TAXI AEREO LTDA)  | 84.8                  | 1100             |
| 6  | Afonso Pena                 | LATAM Airlines Brasil                        | 83.9                  | 19818            |
| 7  | Afonso Pena                 | LATAM AIRLINES GROUP (EX - LAN AIRLINES S/A) | 79.4                  | 620              |
| 8  | Afonso Pena                 | LUFTHANSA CARGO AG                           | 73.4                  | 203              |
| 9  | Afonso Pena                 | TAMPA CARGO S.A.                             | 40.3                  | 211              |
| 10 | Afonso Pena                 | LAN CARGO S.A.                               | 34.1                  | 205              |
| 11 | Afonso Pena                 | CARGOLUX AIRLINES INTERNATIONAL S/A          | 33.1                  | 239              |
| 12 | Brasília                    | LAN PERU S.A.                                | 92.3                  | 976              |
| 13 | Brasília                    | LATAM Airlines Brasil                        | 90.2                  | 75468            |
| 14 | Brasília                    | GOL                                          | 87.9                  | 57346            |
| 15 | Brasília                    | Azul                                         | 85.1                  | 19583            |

↓

▼

196 rows1.299s runtime

Refreshed 12h ago