

MVP - Engenharia de Dados

Operação em solo de aeroportos e companhias aéreas: identificação de gargalos operacionais

Aluno(a): *Emanuel Lacé Aranha*

Email: emmanuel.aranha00@gmail.com

GitHub: https://github.com/Emanuel-Aranha/pos_puc_mvps

Sprint: Engenharia de Dados

Plataforma: Databricks Free Edition

Contexto de Negócios e Perguntas (Etapa 2 e 4.1)

O setor de aviação civil brasileiro convive, de forma estrutural, com problemas de pontualidade, cancelamentos e gargalos operacionais em solo — atrasos que se propagam ao longo do dia, aeroportos com desempenho consistentemente pior que outros, e diferenças relevantes de eficiência entre companhias aéreas que operam nas mesmas condições de infraestrutura.

O objetivo deste trabalho é **identificar gargalos operacionais em solo nos principais aeroportos do Brasil**, cruzando indicadores de pontualidade, cancelamento e tempo de giro (turnaround) de aeronaves, de forma a apontar onde a causa provável do atraso está concentrada — no aeroporto, na companhia aérea ou em fatores sazonais.

Perguntas de negócio

- 1) Quais são as piores taxas de pontualidade por aeroporto e por companhia aérea?
- 1.a) A pontualidade está melhorando ou piorando ao longo dos meses analisados?
- 2) Quais são as justificativas de atraso mais frequentes reportadas pelas companhias?
- 3) Qual o turnaround (tempo de giro em solo) médio por aeroporto?
- 3.a) Um turnaround médio alto se correlaciona com atraso médio de partida no mesmo aeroporto?
- 4) Quais aeroportos/companhias podem ser considerados referência de desempenho e quais são candidatos prioritários a intervenção operacional?
- 5) Existe sazonalidade na pontualidade (ex.: dezembro/janeiro e julho vs. demais meses)?
- 6) O gargalo observado é predominantemente do aeroporto ou da companhia aérea (dispersão de desempenho entre companhias no mesmo aeroporto)?

Observação: todas as perguntas foram mantidas conforme formuladas originalmente. A discussão sobre o que foi ou não plenamente respondido está na seção de Autoavaliação.

Fonte de dados

Os dados utilizados são do VRA — Voo Regular Ativo, disponibilizado publicamente pela ANAC (Agência Nacional de Aviação Civil), contendo o registro de todos os voos regulares realizados no Brasil, com horários previstos e reais de partida e chegada, situação do voo e justificativas de atraso/cancelamento informadas pelas próprias companhias aéreas.

- Período analisado: 2023–2025
- Escopo geográfico: 15 maiores aeroportos do Brasil (origem ou destino)
- Granularidade: uma linha por etapa de voo (par origem-destino em uma data)

Licença de uso

Os dados do VRA são publicados pela ANAC em seu Portal de Dados Abertos (<https://www.anac.gov.br/acesso-a-informacao/dados-abertos>), que segue a política federal de dados abertos do governo brasileiro.

Carga dos Dados (Etapa 4.2)

A coleta foi dividida em duas etapas, em função de uma limitação de rede do compute serverless do Databricks Free Edition, que tem acesso restrito à internet externa e não permite download direto e confiável dos CSVs via requests dentro do notebook:

- **Fora do Databricks (máquina local):** execução do script `baixar_vra_anac.py`, que baixa todos os CSVs mensais do VRA diretamente do site da ANAC.
- **Dentro do Databricks:** upload manual da pasta VRA (contendo todos os CSVs) para um Volume do Unity Catalog ou para a Workspace pessoal.

Uma célula de localização automática (glob recursivo) procura a pasta VRA tanto dentro do Volume quanto na Workspace do usuário, e copia os CSVs encontrados para o Volume. Se a pasta não for encontrada em nenhuma das raízes candidatas, a célula interrompe a execução com um erro explícito (`FileNotFoundException` e mensagem orientando o próximo passo), em vez de falhar de forma pouco clara mais adiante no pipeline.

Ingestão em camada Bronze

Os CSVs da ANAC usam separador ';' e encoding ISO-8859-1 (latin1). A ingestão faz:

- Sanitização dinâmica dos nomes de coluna (remoção de acentos, minúsculas, underscore) — resiliente a mudanças de layout entre anos.
- Renomeação para nomes curtos via dicionário de mapeamento (MAPA_COLUNAS), incluindo a coluna `Codeshare`.
- Leitura de todos os campos como string (`inferSchema=False`) — a tipagem correta só ocorre na camada Silver, conforme o princípio da Arquitetura Medalhão de preservar o dado bruto sem alterações na Bronze.
- Checagem defensiva: se o Volume não tiver nenhum CSV, a célula interrompe com um erro explícito em vez de gerar uma tabela vazia silenciosamente.
- Adição de metadados de controle: `_arquivo_origem` (caminho do arquivo de origem) e `_data_ingestao` (timestamp da carga).
- Gravação como tabela Delta: `mvp_operacao_aerea.bronze.vra_voos`

Repositório com o script de coleta local e o notebook completo:

https://github.com/Emanuel-Aranha/pos_puc_mvps/blob/main/baixar_vra_anac.py

Sigla ICAO	Empresa	Empresa Aérea	Número V	Código	Código Tipo L	Modelo Equipam	Número de Asse	Sigla ICAO Aeroporto O	Descrição Aeroporto Origem
ED	SERVICIOS AEREOS PANAMERICANOS LTDA.	SARPA S A S	1234	0 I	E45		50	SAEZ	MINISTRO PISTARINI INTERNATIONAL AIRPORT (EZEIZA INTERNATIONAL AIRPORT)
ED	SERVICIOS AEREOS PANAMERICANOS LTDA.	SARPA S A S	1234	0 I	E45		50	MMJN	CANCUEN INTL - CANCUEN INTL - MEXICO
ED	SERVICIOS AEREOS PANAMERICANOS LTDA.	SARPA S A S	5332	6 I	E45		50	SBEQ	EDUARDO GOMES - MANAUS - AM - BRASIL
ED	SERVICIOS AEREOS PANAMERICANOS LTDA.	SARPA S A S	5331	9 I	E45		50	SYCJ	CHEDDI JAGAN INTERNATIONAL AIRPORT - GEORGETOWN - GUYANA
ED	SERVICIOS AEREOS PANAMERICANOS LTDA.	SARPA S A S	25332	6 I	E45		0	SBEQ	EDUARDO GOMES - MANAUS - AM - BRASIL
ED	SERVICIOS AEREOS PANAMERICANOS LTDA.	SARPA S A S	5332	2 I	E45		50	SBEQ	EDUARDO GOMES - MANAUS - AM - BRASIL
ED	SERVICIOS AEREOS PANAMERICANOS LTDA.	SARPA S A S	5331	9 I	E45		50	SYCJ	CHEDDI JAGAN INTERNATIONAL AIRPORT - GEORGETOWN - GUYANA
ED	SERVICIOS AEREOS PANAMERICANOS LTDA.	SARPA S A S	25332	6 I	E45		0	SBEQ	EDUARDO GOMES - MANAUS - AM - BRASIL

Partida Prev	Partida Re	Sigla ICAO	Aeroporto D	Descrição Aeroporto Destino	Chegada Prev	Chegada R	Situação	Justificat	Referência	Situação Pa	Situação Che	Codeshare
01/10/2025 07:00		MMJN	CANCUEN INTL	CANCUEN INTL - MEXICO	01/10/2025 12:00		CANCELADO		*****			
01/10/2025 16:00		MDPC	PUNTA CANA	PUNTA CANA - REPUBLICA DOMINICANA	01/10/2025 20:00		CANCELADO		*****			
01/10/2025 00:00	*****	SKBO	EL DORADO INTERNATIONAL AIRPORT	- BOGOTÁ - COLOMBIA	01/10/2025 02:35	*****	REALIZADO		*****	Pontual	Pontual	
15/10/2025 21:00	*****	SBEQ	EDUARDO GOMES - MANAUS - AM - BRASIL		15/10/2025 22:40	*****	REALIZADO		*****	Antecipado	Antecipado	
16/10/2025 00:00	*****	SKBO	EL DORADO INTERNATIONAL AIRPORT	- BOGOTÁ - COLOMBIA	16/10/2025 02:35	*****	CANCELADO		*****			
31/10/2025 21:00	*****	SBEQ	EDUARDO GOMES - MANAUS - AM - BRASIL		31/10/2025 22:40	*****	REALIZADO		*****	Antecipado	Antecipado	
01/10/2025 23:00	*****	SKBO	EL DORADO INTERNATIONAL AIRPORT	- BOGOTÁ - COLOMBIA	01/10/2025 01:10	*****	REALIZADO		*****			
01/10/2025 23:00	*****	KFNA	MIAI INTERNATIONAL AIRPORT	- MIAMI, FLORIDA - ESTADOS UNIDOS DA AMÉRICA	02/10/2025 07:35	*****	REALIZADO		*****	Antecipado	Antecipado	
01/10/2025 00:05	*****	SBGL	AEROPORTO INTERNACIONAL DO RIO DE JANEIRO (GALEÃO) - ANTONIO CARLOS J		01/10/2025 08:20	*****	REALIZADO		*****	Pontual	Pontual	
01/10/2025 23:15	*****	KFNA	MIAI INTERNATIONAL AIRPORT	- MIAMI, FLORIDA - ESTADOS UNIDOS DA AMÉRICA	02/10/2025 07:35	*****	REALIZADO		*****	Antecipado	Antecipado	

Modelagem e Catálogo de Dados (Etapa 4.3)

O modelo adotado é um esquema flat por conceito, típico de Data Lake, com uma tabela fato e três dimensões de apoio:

- **fVoos (fato):** uma linha por etapa de voo que toca os 15 aeroportos do escopo (como origem OU destino), com os dois lados da rota enriquecidos e a companhia identificada.
- **dAeroporto (dimensão):** todos os aeroportos observados na base (não só os 15 do escopo), com um indicador booleano de quais são monitorados.
- **dCia (dimensão):** companhias aéreas identificadas na base, com nome comercial derivado dos próprios dados.
- **dCalendario (dimensão):** datas de 2023-01-01 a 2025-12-31, com indicador de alta temporada.
- **turnaround_estimado (tabela de apoio):** estimativa de tempo de giro em solo por aeroporto/companhia (proxy — ver limitações).

Catálogo de dados

dAeroporto (gold)

Cobre todos os aeroportos observados como origem ou destino na base — não apenas os 15 do escopo.

Coluna	Tipo	Descrição
icao	string	Código ICAO do aeroporto. Chave primária.
nome_aeroporto	string	Nome do aeroporto. Para os 15 aeroportos do escopo, nome curado manualmente; para os demais, derivado automaticamente da descrição bruta da ANAC (primeiro segmento antes de ' - ').
cidade_uf	string	Cidade/UF (aeroportos do escopo, curado) ou cidade/país (demais aeroportos, derivado da descrição bruta).
aeroporto_monitorado	boolean	Indica se o aeroporto é um dos 15 do escopo deste MVP. Usado como filtro nas consultas de negócio da Etapa 6.
descricao_aeroporto	string	Descrição bruta do aeroporto tal como veio no CSV da ANAC (mais frequente entre os arquivos mensais) — mantida para rastreabilidade/linhagem.

dCia (gold)

Cobre 100% dos códigos de companhia vistos na base, derivados dos próprios dados.

Coluna	Tipo	Descrição
icao	string	Código ICAO da companhia aérea. Chave primária.
nome_cia	string	Nome comercial. Nome mais frequente (moda) da coluna 'Empresa Aérea' do CSV por código ICAO; um pequeno dicionário de exceções (mapa_cias_override) tem prioridade para os casos em que o nome bruto vem inconsistente entre arquivos.

dCalendario (gold)

Coluna	Tipo	Descrição
date	date	Data (2023-01-01 a 2025-12-31). Chave primária.
day_of_month	int	Dia do mês (1-31).
day_name	string	Nome do dia da semana.
month	int	Mês (1-12).
month_name	string	Nome do mês.
quarter	int	Trimestre (1-4).
year	int	Ano.
days_in_month	int	Quantidade de dias no mês.
alta_temporada	boolean	Indica se o mês é dezembro, janeiro ou julho — usado na Pergunta 5.

fVoos (gold)

Coluna	Tipo	Descrição
icao_empresa	string	Código ICAO da companhia aérea que operou a etapa de voo. Chave estrangeira → dCia.icao.
numero_voo	string	Número do voo.
codigo_di	string	Código de identificação do documento de itinerário (DI).
codigo_tipo_linha	string	Código do tipo de linha aérea (nacional, internacional, etc.).
modelo Equipamento	string	Modelo da aeronave utilizada na etapa.
numero_assentos	int	Número de assentos ofertados na aeronave (tipado como inteiro na Silver).
icao_origem	string	Código ICAO do aeroporto de origem. Chave estrangeira → dAeroporto.icao.
icao_destino	string	Código ICAO do aeroporto de destino. Chave estrangeira → dAeroporto.icao.
partida_prevista	timestamp	Data/hora prevista de partida.
partida_real	timestamp	Data/hora real de partida (nulo se o voo não decolou).
chegada_prevista	timestamp	Data/hora prevista de chegada.
chegada_real	timestamp	Data/hora real de chegada (nulo se o voo não pousou).
atraso_partida_min	double	Diferença em minutos entre partida real e prevista.
atraso_chegada_min	double	Diferença em minutos entre chegada real e prevista.
situacao_voo	string	Domínio esperado: REALIZADO, CANCELADO (confirmar valores distintos observados na Etapa 5).
justificativa	string	Texto livre preenchido pela companhia aérea justificando atraso/cancelamento — não padronizado.
situacao_partida	string	Situação da partida informada pela companhia.
situacao_chegada	string	Situação da chegada informada pela companhia.
codeshare	string	Indicador de voo codeshare, conforme reportado pela ANAC. Disponível na Bronze; ainda não explorado nas 8 perguntas atuais.
nome_aeroporto_origem	string	Nome do aeroporto de origem (join com dAeroporto por icao_origem).

Coluna	Tipo	Descrição
cidade_uf_origem	string	Cidade/UF do aeroporto de origem.
origem_no_escopo	boolean	true se icao_origem é um dos 15 aeroportos monitorados. Usado para filtrar consultas de pontualidade de partida.
nome_aeroporto_destino	string	Nome do aeroporto de destino (join com dAeroporto por icao_destino).
cidade_uf_destino	string	Cidade/UF do aeroporto de destino.
destino_no_escopo	boolean	true se icao_destino é um dos 15 aeroportos monitorados.
nome_cia	string	Nome comercial da companhia aérea (join com dCia por icao_empresa).

Linagem: fVoos e turnaround_estimado derivam de silver.vra_voos, que por sua vez deriva de bronze.vra_voos (CSVs originais da ANAC, sem transformação). dAeroporto é derivada da própria Bronze (union de icao_origem/icao_destino com suas descrições), sobreposta pelos nomes curados dos 15 aeroportos do escopo. dCia é derivada da coluna 'Empresa Aérea' da própria Bronze, sobreposta por um pequeno dicionário de exceções.

Chaves primárias e estrangeiras

Nenhuma chave primária ou estrangeira estava declarada na primeira versão do notebook — o relacionamento entre as tabelas existia só implicitamente, dentro dos joins do PySpark, e o Catalog Explorer do Databricks não desenhava nenhum relacionamento entre elas. A tabela abaixo resume as chaves adicionadas:

Constraint	Tabela	Coluna(s)	Tipo / Referência
pk_daeroporto	dAeroporto	icao	PRIMARY KEY
pk_dcia	dCia	icao	PRIMARY KEY
pk_dcalendario	dCalendario	date	PRIMARY KEY
pk_turnaround_estimado	turnaround_estimado	aeroporto, icao_empresa, evento_hora	PRIMARY KEY
fk_fvoos_dcia	fVoos	icao_empresa	FOREIGN KEY → dCia.icao
fk_fvoos_daeroporto_origem	fVoos	icao_origem	FOREIGN KEY → dAeroporto.icao
fk_fvoos_daeroporto_destino	fVoos	icao_destino	FOREIGN KEY → dAeroporto.icao
fk_fvoos_dcalendario	fVoos	data_prevista_partida	FOREIGN KEY → dCalendario
fk_turnaround_daeroporto	turnaround_estimado	aeroporto	FOREIGN KEY → dAeroporto.icao
fk_turnaround_dcia	turnaround_estimado	icao_empresa	FOREIGN KEY → dCia.icao
fk_turnaround_dcalendario	turnaround_estimado	data_evento	FOREIGN KEY → dAeroporto.icao

Importante: constraints de PRIMARY KEY/FOREIGN KEY no Delta/Unity Catalog são **informativas** — não são impostas pelo motor de escrita (o Delta não bloqueia, por exemplo, a gravação de uma linha

com uma chave estrangeira inválida). Elas documentam o modelo e habilitam o diagrama de relacionamento do Catalog Explorer. A garantia de integridade real vem de como o pipeline foi construído (as dimensões cobrem 100% dos códigos referenciados por fVoos, por construção) e é auditada explicitamente na Etapa 4.5 (Qualidade de Dados / Integridade Referencial), onde a contagem de órfãos deve ser zero.

Pipeline de Dados (Etapa 4.4)

Todo o pipeline foi implementado em um único notebook Python, organizado em seções sequenciais (markdown + código) que seguem a Arquitetura Medalhão: Coleta (Bronze) → Modelagem + chaves primárias (Etapa 3) → Carga Silver/Gold + chaves estrangeiras (Etapa 4) → Qualidade e integridade referencial (Etapa 5) → Análise (Etapa 6). A opção por um notebook único, em vez de ramificar em vários notebooks por tabela, foi mantida por manter a leitura linear do fluxo completo mais simples de acompanhar e de reexecutar do zero — todas as escritas usam `overwriteSchema` para permitir reexecução mesmo quando o esquema de uma tabela muda.

Bronze → Silver

- Conversão dos campos de data/hora (texto no formato dd/MM/yyyy HH:mm) para timestamp real.
- Conversão de `numero_assentos` para inteiro (antes permanecia como string).
- Cálculo de `atraso_partida_min` e `atraso_chegada_min` (diferença em minutos entre horário real e previsto).
- Filtro de escopo: mantém a etapa de voo se a origem OU o destino estiver entre os 15 aeroportos monitorados.
- Gravação como tabela Delta: `silver.vra_voos`
- Vale ressaltar, até mesmo como recomendação do professor durante uma das aulas de dúvidas, que os dados nulos não foram descartados a princípio, embora foi observado alguns dados de “data prevista de partida” nula durante o processo, não necessariamente era um erro pois podia ser um caso de voos remanejados ou então voos cancelados.



Silver → Gold

- **dAeroporto e dCia:** construídas a partir da própria Bronze (ver Etapa 4.3), com chave primária declarada logo em seguida.
- **Estimativa de turnaround (proxy):** a base VRA não identifica a aeronave por matrícula, então o turnaround real por aeronave não pode ser calculado. Como proxy, o pipeline une os eventos de chegada e partida da mesma companhia no mesmo aeroporto, ordena por horário (Window function), e usa `lead()` para encontrar a próxima partida após cada chegada, descartando intervalos negativos ou maiores que 12h (720 min) como ruído.
- **fVoos:** join duplo de `silver.vra_voos` com `dAeroporto` (uma vez para origem, outra para destino) e com `dCia`, resultando na tabela gold consolidada com ambos os lados da rota nomeados. Em seguida, as chaves estrangeiras são declaradas (ver Etapa 4.3). Nessa etapa já fizemos o descarte dos dados de voos com data prevista de partida nula, por conta do intuito final do trabalho: Analisar atraso. Portanto, se não temos data prevista de partida, não conseguimos calcular o dado de atraso.

Scripts completos disponibilizados no repositório:

https://github.com/Emanuel-Aranha/pos_puc_mvps/blob/main/MVP_ANAC_VRA.ipynb

Além disso, é possível visualizar o schema flat nas imagens abaixo.



Qualidade de Dados (Etapa 4.5)

A verificação de qualidade foi feita sobre a tabela gold.fVoos, cobrindo completude, consistência de domínio, outliers e integridade referencial:

- Completude: contagem e percentual de nulos para as colunas icao_empresa, icao_origem, icao_destino, situacao_voo, partida_real e chegada_real.
- Consistência de domínio: listagem dos valores distintos de situacao_voo, para confirmar que o campo está restrito aos valores esperados.
- Outliers: contagem de registros com atraso de partida acima de 24h (1440 min), tratados como suspeitos de erro de digitação de data na fonte.

Interpretação documentada no próprio notebook: nulos em partida_real/chegada_real são esperados para voos com situacao_voo = 'CANCELADO' e não devem ser removidos — apenas tratados como ausência de execução nas análises de pontualidade. Nulos em outros campos indicariam um problema de qualidade a investigar.


Integridade referencial

Como as chaves estrangeiras do Unity Catalog são apenas informativas (não impedem uma escrita inconsistente), o notebook mede diretamente a integridade do modelo em vez de apenas presumi-la a partir das constraints declaradas:

- Contagem de voos sem nenhum aeroporto (origem ou destino) no escopo monitorado — esperado 0, valida o filtro da Silver.
- Contagem de voos com nome_aeroporto_origem ou nome_aeroporto_destino nulos — esperado 0, valida a cobertura completa da nova dAeroporto.
- Contagem de voos com nome_cia nulo — esperado 0, valida a cobertura completa da nova dCia.

```
=== Checagem de integridade referencial (valida o modelo/PK/FK das Etapas 3-4) ===  
  
Voos sem NENHUM lado (origem/destino) no escopo monitorado (esperado: 0, é a checagem do filtro da Silver): 0  
Voos com nome_aeroporto_origem nulo (cobertura da nova dAeroporto, esperado: 0): 0  
Voos com nome_aeroporto_destino nulo (cobertura da nova dAeroporto, esperado: 0): 0  
Voos com nome_cia nulo (cobertura da nova dCia, esperado: 0): 0  
Voos com data_partida_prevista nula (partida_prevista não parseou, esperado: 0): 76131
```

Aqui podemos ver que existem diversos voos com data prevista de partida nula, apesar de ser um indicador de possível erro no processo, é possível interpretar de outra forma: Voos que foram cancelados. Para isso será necessário aprofundar por status do voo, como podemos ver abaixo



```
Just now (2s) 35  
  
%sql  
select count(*) from fVoos  
where data_partida_prevista is null and situacao_voo = "REALIZADO"  
  
> See performance \(1\)  
  
Table +  
  
count(*)  
1 76.13K
```

Com isso podemos entender que realmente existe uma inconsistência nos dados, afetando aproximadamente 3% da base. Não foi encontrado também nenhuma justificativa para esses dados estarem nulos. Dessa forma, foi reestruturada a base fVoos de modo que não constasse essas

inconsistências nos dados e que atrapalhasse as respostas das perguntas, repetindo o mesmo processo para “partida_real” e “chegada_real” (e situação voo não igual a realizado, pois voos não realizados deveriam ter partida_real e chegada_real nulas). Resultando em aproximadamente 2.7 M de linhas válidas.

Análise de Dados (Etapa 4.5)

Cada pergunta de negócio definida no objetivo foi respondida por uma consulta SQL sobre a camada gold. Como fVoos agora traz os dois lados da rota (origem e destino), a maioria das consultas filtra explicitamente por origem_no_escopo — sem esse filtro, uma pergunta como 'pontualidade por aeroporto' poderia somar, para um mesmo aeroporto, tanto voos que realmente partiram dele quanto voos que só passaram por ele como destino, o que não faz sentido para um indicador de pontualidade de partida.

Pergunta 1 — piores taxas de pontualidade por aeroporto e companhia

Calcula, para cada combinação aeroporto de origem × companhia, o percentual de voos pontuais (atraso de partida ≤ 15 min) entre os voos realizados que de fato partiram de um aeroporto do escopo (origem_no_escopo), considerando apenas combinações com mais de 100 voos.

```
O topo da tabela encontramos apenas linhas aéreas cargueiras, o que é interessante de analisar pensando que quando se trata de cargas, 15 minutos de atraso não é um tempo tão relevante assim. Porém mais no meio da tabela vemos que é bem distribuído, não parecendo um problema por companhia pois as mesmas companhias que estão mais no meio da tabela tem destaque também no bottom da tabela. Exemplo a azul, em guarulhos, tem 75% de pontualidade. Mas em outros aeroportos possuem mais que 80%, num contexto geral. Gerando a dúvida: Será que em grandes companhias como Gol, azul e Latam, o gargalo está mais relacionado ao aeroporto e não a companhia?
```

Pergunta 1.a — evolução mensal da pontualidade

Agrupa o percentual de pontualidade por mês e por aeroporto de origem (origem_no_escopo), permitindo visualizar tendência de melhora ou piora ao longo do período 2023–2025.

```
Aqui não parece ter uma evolução clara, porém ao rodar a primeira query vemos claramente um outlier em maio de 2023. Ao rodar uma segunda query percebemos que estamos praticamente sem dados em maio de 2023, mostrando um erro na tabela. Investigando as origens vemos que o erro está em um dos CSV's de entrada.
```

Pergunta 2 — justificativas de atraso mais frequentes

Normaliza o texto livre do campo justificativa (trim + upper) e conta a frequência de cada justificativa sobre todo o fVoos (sem filtro de origem_no_escopo, propositalmente — ver nota de escopo no notebook), calculando o percentual sobre o total de registros preenchidos.

Curiosamente as justificativas de atraso não estão preenchidas, verificando os csv's de entrada essa hipótese se confirma. As companhias não tem o costume de preencher essa informação ou o sistema que exportou os csvs para o site da ANAC não exporta essa informação.

Pergunta 3 — turnaround médio por aeroporto

Junta `turnaround_estimado` com `dAeroporto` e calcula a média de `turnaround_min` por aeroporto, restringindo a `aeroporto_monitorado` (necessário agora que `dAeroporto` cobre todos os aeroportos, não só os 15 do escopo).

Observando os aeroportos com maiores turnaround vemos que Guarulhos, Eduardo Gomes e Galeão possuem valores muito altos, gerando um maior custo para a companhia aérea, visto que o avião no solo gera custo enquanto um avião no ar gera lucro. Assim percebemos também que Congonhas possui uma operação em solo exemplar, em questão de turnaround.

Pergunta 3.a — turnaround alto correlaciona com atraso médio de partida?

Cruza o turnaround médio por aeroporto com o atraso médio de partida por aeroporto (restrito a `origem_no_escopo`), agora também unido a `dAeroporto` para exibir o nome do aeroporto em vez de apenas o código ICAO.

Não existe uma correlação direta, mas os 2 aeroportos com maior turnaround tem também um alto atraso médio. Mas os valores intermediários oscilam, não confirmando essa hipótese. Além disso, Congonhas possui o menor turnaround e não possui o menor atraso médio

Pergunta 4 — aeroportos/companhias referência vs. candidatos a intervenção

Combina, por aeroporto de origem (`origem_no_escopo`), o percentual de pontualidade e o percentual de cancelamento em uma única consulta, permitindo classificar aeroportos como referência (alta pontualidade, baixo cancelamento) ou candidatos a intervenção (padrão oposto).

Brasília lidera em pontualidade e percentual de cancelamento, sendo um ótimo candidato a aeroporto de referência em operação. Já como candidato a intervenção, temos Eduardo Gomes com um alto percentual de cancelamento e baixa pontualidade

Pergunta 5 — sazonalidade

Junta `fVoos` com `dCalendario` por data e agrupa pontualidade e atraso médio por mês do ano, permitindo comparar dezembro/janeiro e julho (alta temporada) contra os demais meses. Diferente das perguntas anteriores, aqui não se filtra por `origem_no_escopo` — a sazonalidade é medida sobre todo o movimento que toca os aeroportos do escopo, partindo ou chegando.

Não parece existir uma piora por sazonalidade, mas existe sim uma piora no serviço no ultimo trimestre. Mas a hipótese é anulada quando julho, um mês de alta temporada, possui uma das maiores performances operacionais

Pergunta 6 — gargalo é do aeroporto ou da companhia?

Calcula a pontualidade por aeroporto de origem × companhia (origem_no_escopo, com filtro de amostra mínima de 200 voos) para observar a dispersão de desempenho entre companhias dentro do mesmo aeroporto.

A resposta é bem simples analisando os dados acima> É a companhia e não o aeroporto.

A evidência mais forte é o aeroporto de viracopos, onde as cargueiras variam performance de 90% de pontualidade (FedEx) vs 14% de pontualidade (Atlas Air), mas não para por ai, em Guarulhos a azul possui 89% vs latam com 75%.

Outra evidência é a marcação de algumas empresas que performam consistentemente mal, como por exemplo a TAP, com todas as performances inferiores a 71%. Assim, entre outros casos, podemos concluir que a empresa que possui uma operação não ideal e não o aeroporto, podendo intensificar a piora caso o aeroporto não tenha um histórico bom, porém boas empresas continuam com boas performances mesmo nesses aeroportos que possuem atrasos constantes.

Considerações finais

Pontos de melhoria

- **Turnaround por proxy:** a base VRA não identifica a aeronave por matrícula, então o turnaround estimado (mesma companhia, mesmo aeroporto, próxima partida) é uma aproximação. Incorporar uma base com matrícula da aeronave (ex.: dados de tráfego aéreo do DECEA/Redemet) permitiria calcular o turnaround real por aeronave.
- **Nomes derivados para aeroportos fora do escopo:** para os aeroportos que não são um dos 15 do escopo, nome e cidade são derivados por um split simples da descrição bruta da ANAC ('NOME - CIDADE - PAÍS'). Para descrições em formato diferente do padrão, isso pode gerar nomes truncados ou pouco legíveis. Uma tabela de referência oficial de aeroportos (ex.: base IATA/OpenFlights) resolveria isso com mais precisão — não é crítico hoje porque esses campos só aparecem de forma secundária (nenhuma das 8 perguntas depende do nome de aeroportos fora do escopo).
- **Constraints informativas:** as chaves primária/estrangeira adicionadas ao Unity Catalog não são impostas pelo Delta — servem como documentação do modelo e para o diagrama de

relacionamento do Catalog Explorer. A garantia de integridade real depende de como o pipeline constrói as dimensões e é auditada na Etapa 5.

- **Justificativas de atraso não preenchidas:** A pergunta 2 não foi possível responder devido a falta das justificativas

Autoavaliação

No fim das contas, fiquei bem satisfeito com o que consegui responder. As Perguntas 1, 1.a, 4, 5 e 6 saíram com respostas sólidas e o que mais me deixou confiante foi ver os resultados batendo entre si sem eu ter forçado. Guarulhos e Congonhas aparecem como o mesmo tipo de problema tanto na Pergunta 1 quanto na 4 e na 6, e Eduardo Gomes se repete como ponto fora da curva no cancelamento e depois de novo quando eu abro por companhia. Quando os números concordam assim, de lugares diferentes da análise, dá uma segurança boa de que não é coincidência.

A Pergunta 5 foi provavelmente a que mais me ensinou alguma coisa. Eu tinha entrado com a expectativa de que dezembro, janeiro e julho seriam os meses ruins, e não é bem isso que acontece. O que os dados mostram é uma piora que vai se acumulando de outubro pra novembro pra dezembro, e julho, pelo contrário, fica até acima da média do ano. Gostei de ter deixado a hipótese errada aparecer e mudado de ideia em cima do dado, em vez de tentar encaixar o resultado no que eu já esperava.

Já as Perguntas 2, 3 e 3.a eu diria que ficaram só parcialmente resolvidas, e aí o limite não foi de esforço, foi da própria base: o VRA não traz a matrícula da aeronave, então o turnaround que calculei é uma estimativa (mesma companhia, mesmo aeroporto, próxima partida saindo dali), não o tempo de giro real de um avião específico. Deixei isso documentado e chequei que a parcela de estimativas descartadas por serem ruído (mais de 12h de intervalo) era pequena, mas de toda forma é uma resposta aproximada, além disso a falta de justificativa é um fator crucial aqui para a resposta da pergunta 2.

Em termos técnicos, confesso que SQL e modelagem relacional não me pegaram de surpresa — já tinha visto isso em disciplinas anteriores. E a parte de engenharia de dados em si (ETL, as camadas Bronze/Silver/Gold, PySpark) também fluiu mais fácil do que eu esperava, provavelmente porque já tinha passado por algo parecido trabalhando como analista de dados na área de previdência privada, na XP, antes de entrar no curso. O que realmente me deu trabalho foi outra coisa: revisar o modelo relacional depois que percebi um erro que eu mesma tinha cometido sem perceber. Minha primeira versão da dAeroporto só cobria os 15 aeroportos do escopo, e isso fazia com que voos em que o aeroporto do escopo era o destino (e não a origem) simplesmente sumissem das análises agrupadas por aeroporto — sem erro nenhum aparecendo na tela, só um resultado sutilmente errado. Foi meio desconfortável perceber isso, porque eu já tinha rodado tudo e parecia que estava certo. Tive que reconstruir a dimensão do zero considerando todos os códigos ICAO da base pra só depois conseguir declarar chave primária e estrangeira de verdade. Teve também um bug de encoding — o arquivo é UTF-8 mas em algum momento eu tratei como Latin-1 — que só ficou óbvio quando vi os nomes das companhias saindo com "Ã" no lugar de acento no resultado de uma query. Isso me ensinou uma lição que acho que vou levar: não basta o pipeline rodar sem erro, é preciso realmente olhar o dado que sai no fim. Fora do código, teve ainda uma dor de cabeça mais prática na coleta: o compute do Databricks Free Edition tem acesso restrito à internet, então não deu pra baixar os CSVs da ANAC direto pelo notebook, precisei baixar na minha máquina e subir manualmente.

Mas, sendo bem sincero, a parte mais difícil do trabalho inteiro não foi nada disso. Foi entender a própria aviação. Eu gosto do assunto, sempre gostei, mas gostar de longe é bem diferente de

conseguir explicar por que Viracopos concentra tanta cargueira, por que Manaus tem um perfil de cancelamento tão diferente do resto, ou o que exatamente significa turnaround na prática do dia a dia de um aeroporto. Passei bem mais tempo pesquisando sobre o setor pra conseguir interpretar os números com um mínimo de propriedade do que efetivamente escrevendo código, no fim, foi a parte que eu mais gostei do processo inteiro, sair sabendo bem mais sobre aviação do que sabia quando comecei.